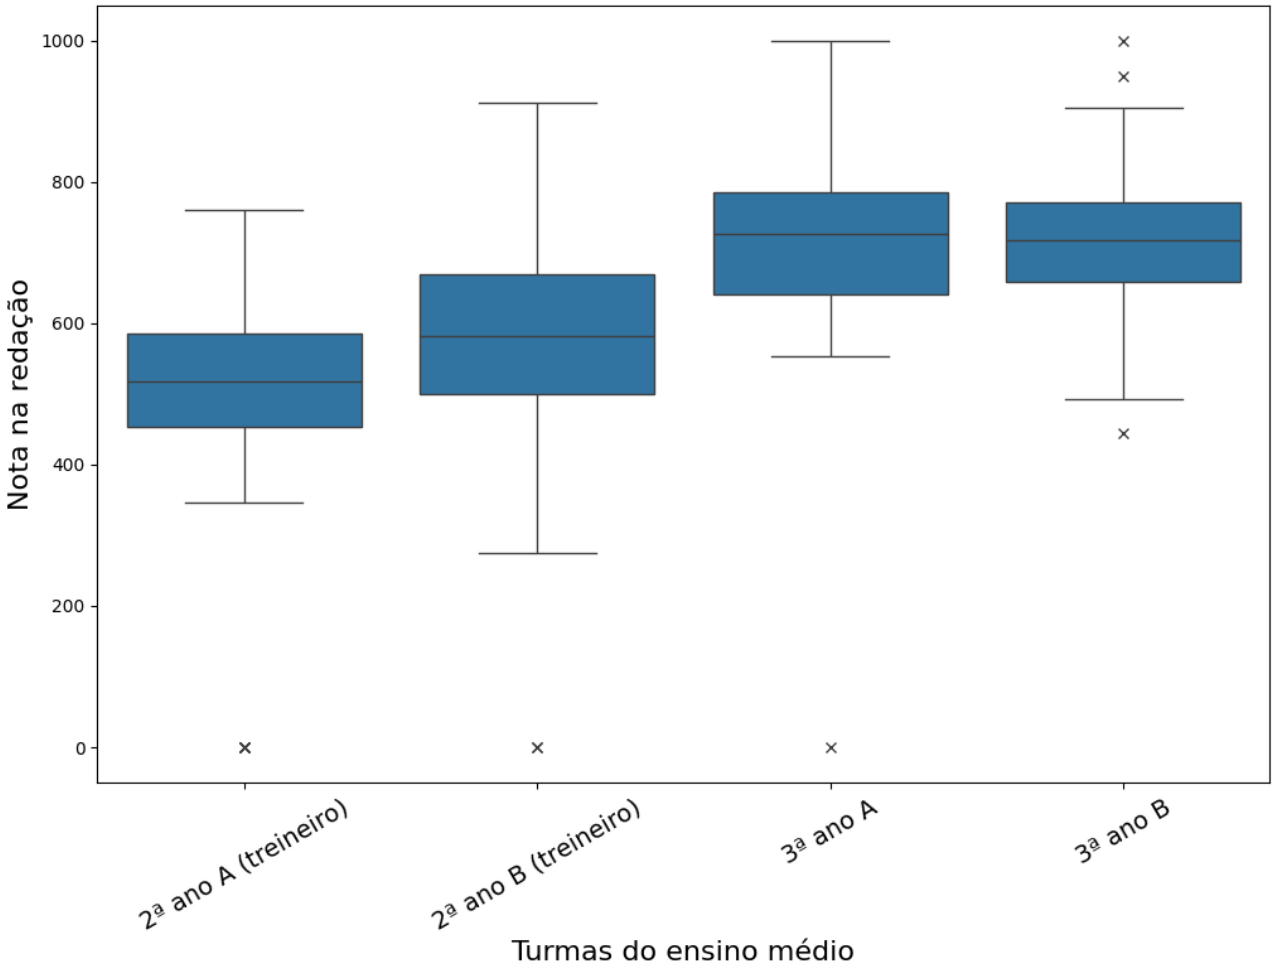
Lista de Exercícios - Quinzena 1
Módulo 1: Estatística para Ciência de Dados
Professora: Cibele Russo
Monitor: Natan Hilário

1. Em uma escola, foi realizado um levantamento das notas de 4 turmas de alunos do ensino médio na redação do Enem 2024. Os resultados podem ser resumidos no seguinte gráfico de *boxplot*.



Com base na figura acima, classifique as seguintes afirmações em verdadeiro (V) e falso (F), justificando caso seja falso.

( ) Podemos afirmar que existe uma diferença estatisticamente significativa entre as turmas

( ) A mediana dos alunos do 3º ano é superior à mediana dos alunos do 2º ano

( ) A turma do 3º ano B apresentou notas maiores, pois nenhum aluno zerou a redação

( ) Um aluno do 3º ano B qualquer obteve uma nota superior a todos os alunos do 2º ano A

( ) Os alunos com nota *outliers* devem ser desconsiderados da análise para uma melhor análise estatística

( ) A comprovação de que o terceiro ano apresentou notas superiores requer o uso de testes de hipótese.

2. Considere o código abaixo para o carregamento dos dados "iris", na linguagem *Python*.

```
from sklearn import datasets

# Carrega o conjunto de dados
data = datasets.load_iris(as_frame = True)
df_iris = data.frame
df_iris.columns = ["sepal_length", "sepal_width",
"petal_length", "petal_width", "species"]

# Atualiza para os nomes das especies
df_iris["species"] = df_iris["species"].astype(str)
df_iris.loc[df_iris["species"] == "0", "species"] = "setosa"
df_iris.loc[df_iris["species"] == "1", "species"] = "versicolor"
df_iris.loc[df_iris["species"] == "2", "species"] = "virginica"

df_iris.head(4)
```

a) Obtenha as métricas relevantes para a distribuição de cada uma das variáveis (média, desvio-padrão, coeficiente de variação, mediana e quartis).

b) Construa gráficos para avaliar a associação entre cada variável quantitativa e a variável "species".

c) Construa uma matriz de correlações entre as variáveis numéricas e interprete os resultados.

d) Construa gráficos para identificar a associação entre pares das variáveis quantitativas e interprete os resultados.

3. O código abaixo carrega uma base de dados de filmes da Netflix com as variáveis pré-tratadas (mais informações em `https://www.kaggle.com/datasets/shivamb/netflix-shows`).

```
import pandas as pd
pd.read_csv("https://raw.githubusercontent.com/cibelerusso/" +
           "Datasets/main/netflix_titles_dataset.csv")
df.head(3)
```

Com base neste conjunto de dados, construa tabelas de frequência relativa, gráficos de barras e de mosaico para avaliar a associação entre as variáveis "country" (país de origem do filme) e "rating" (classificação indicativa do filme: 14, 18 ou L). Existem indícios que nos apontem uma possível associação?

4. Com relação à análise exploratória de dados, considere as seguintes afirmações:

I. Os gráficos de dispersão são úteis para identificar associação entre variáveis quantitativas.

II. A maior vantagem dos gráficos de *boxplot* é o fato de que é possível identificar diferenças estatisticamente significantes apenas ao olhar a figura.

III. O coeficiente de correlação de Spearman quantifica a associação linear entre duas variáveis qualitativas

IV. Os *outliers* não devem ser retirados do conjunto de dados sem uma boa justificativa para tal.

V. O coeficiente de variação é uma métrica adimensional da distribuição dos dados

VI. Para distribuições unimodais (densidade com um ponto de máximo apenas) assimétricas a direita, temos que moda $<$ mediana $<$ média.

As alternativas corretas são

a) IV, e VI apenas

b) II e III e V

c) I, V e VI

d) I, IV, V e VI

e) todas as alternativas

5. Em um jogo de RPG. suponha o lançamento de um dado honesto de 20 faces, Considere os seguintes eventos:

- A: o número é maior que 5,
- B: o número é primo,
- C: o é par,

a) Obtenha a probabilidade dos eventos $A \cap B$, $A \cap C$, $B \cap C$ e $A \cap B \cap C$.

b) Supondo que, caso o jogador obtenha um resultado menor ou igual a 4, seu personagem morre, qual a probabilidade de que ele fique vivo, dado que ocorreu o evento A?

c) Supondo que, caso o jogador obtenha um resultado menor ou igual a 4, seu personagem morre, qual a probabilidade de que ele fique vivo, dado que ocorreu o evento B?

6. Uma empresa procura investigar três perfis propagadores de notícias falsas em uma rede social. No geral, 75% das informações publicadas pelo perfil A são falsas, diferente dos 30% e 50% referentes aos perfis B e C, respectivamente. Nos últimos 6 meses, o perfil A fez um total de 85 postagens, o perfil B fez 150, enquanto que o perfil C fez 230. O investigador garante que uma nova notícia falsa foi originada em um desses perfis. Qual a probabilidade de que essa notícia seja dos perfis A, B e C, respectivamente?

7. Considere o seguinte jogo envolvendo o lançamento de moedas. Uma moeda justa é lançada repetidamente até que seja observada uma "coroa". Supondo que nos lançamentos foi observado "cara" por $k > 0$ lançamentos, então o jogador recebe como recompensa de 2^k reais. Ou seja, se os lançamentos forem dados por (cara, cara, coroa), a recompensa é dada por $2^2 = 4$ reais. Caso ocorra "coroa" no primeiro lançamento, o jogador recebe 2 reais.

a) Descreva o espaço amostral, Ω do experimento.

b) Obtenha a função massa de probabilidade para a recompensa do jogador

c) Calcule o valor esperado da recompensa do jogador

d) O problema acima é conhecido como Paradoxo de São Petesburgo. Com base nos resultados obtidos acima, qual uma possível motivação para o nome "paradoxo"?

8. Com relação a variáveis aleatórias (v.a.'s), classifique as seguintes afirmações em verdadeiro (V) e falso (F), justificando caso seja falso.

( ) A probabilidade de que uma variável aleatória contínua, X, seja igual a 2 é sempre igual a zero.

( ) Se X é uma v.a. discreta, suas probabilidades são descritas pela função densidade de probabilidade, enquanto que se X é contínua, utilizamos a função massa de probabilidade.

( ) É possível que uma variável aleatória discreta assuma infinitos possíveis valores.

( ) A função de distribuição acumulada de uma v.a. pode ser obtida por uma integral, no caso contínuo e um somatório, no caso discreto.

( ) A esperança de uma variável aleatória sempre existe e é finita.

( ) Quando $E[X^2] < \sqrt{E[X]}$, a variável X apresenta variância negativa.

( ) Se $X > 1$, então $E[X] > 1$.

9. Seja X variável contínua com densidade

$$f(x) = \lambda e^{-\lambda x}.$$

Calcule a sua função densidade acumulada, a esperança e variância de X.

10. Seja X variável discreta que assume os valores $0, 1, 2, 3$ e 4 com probabilidades 0.2, 0.3, 0.3, 0.05 e 0.15, respectivamente. Obtenha a média e a variância de X.