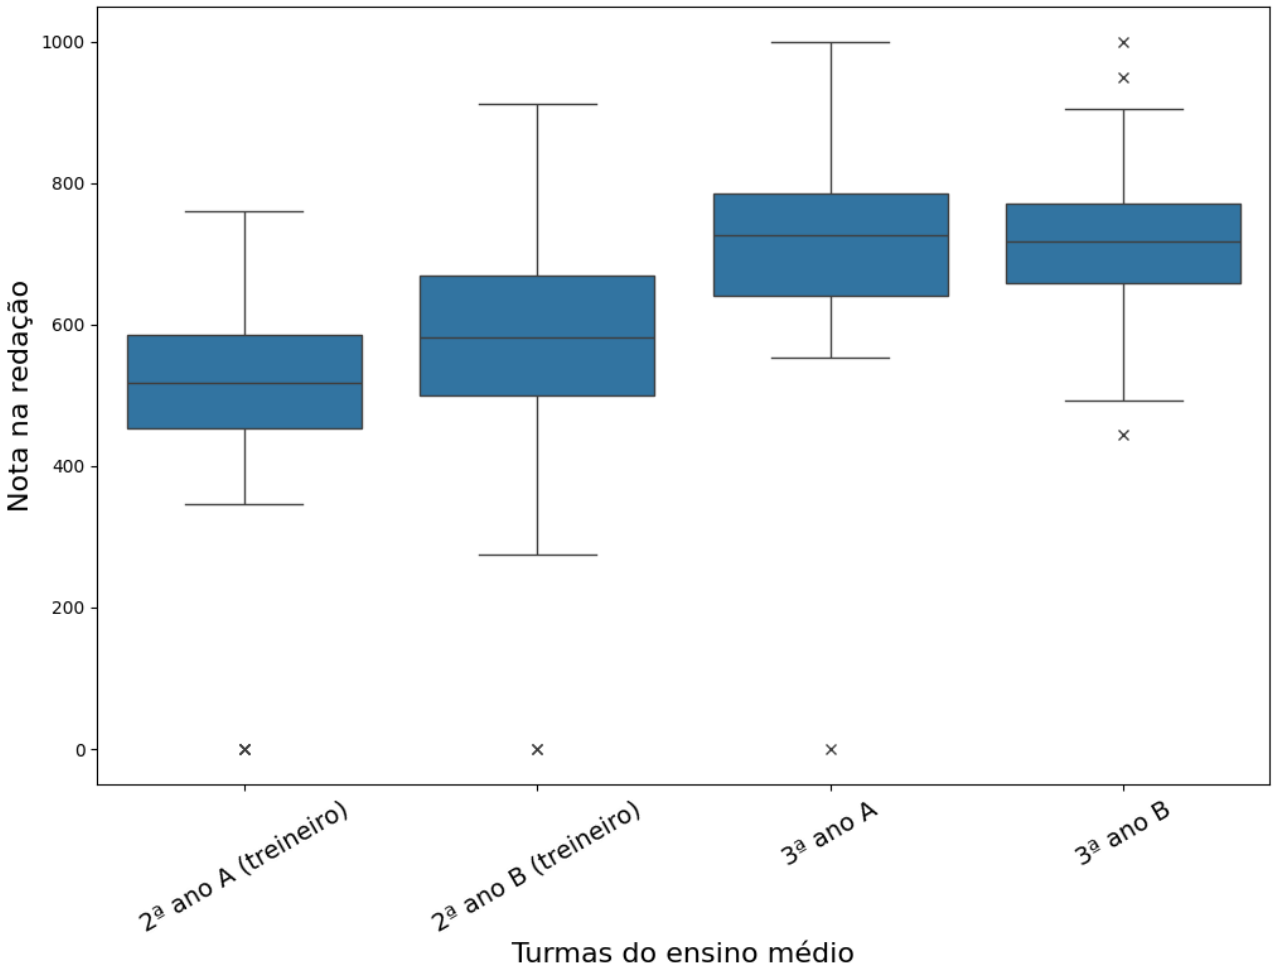
Lista de Exercícios com GABARITO - Quinzena 1
Módulo 1: Estatística para Ciência de Dados
Professora: Cibele Russo
Monitor: Natan Hilário

1. Em uma escola, foi realizado um levantamento das notas de 4 turmas de alunos do ensino médio na redação do Enem 2024. Os resultados podem ser resumidos no seguinte gráfico de *boxplot*.



Com base na figura acima, classifique as seguintes afirmações em verdadeiro (V) e falso (F), justificando caso seja falso.

(F) Podemos afirmar que existe uma diferença estatisticamente significativa entre as turmas
Para tirarmos conclusões definitivas sobre significâncias estatísticas, devem ser realizados testes de hipótese.

(V) A mediana dos alunos do 3º ano é superior à mediana dos alunos do 2º ano

(F) A turma do 3º ano B apresentou notas maiores, pois nenhum aluno zerou a redação
A presença de alguns pontos diferentes na amostra não representa o comportamento do todo (turma). Para isso, são necessários testes de hipótese.

(F) Um aluno do 3º ano B qualquer obteve uma nota superior a todos os alunos do 2º ano A
Pelo gráfico, vemos que a maior nota do 2º ano A é próxima de 800, enquanto a menor nota do 3º ano B é próxima de 400

(F) Os alunos com nota *outliers* devem ser desconsiderados da análise para uma melhor análise estatística

A retirada de *outliers* da análise deve ser muito bem justificada para evitar a inclusão de vieses nos dados.
(V) A comprovação de que o terceiro ano apresentou notas superiores requer o uso de testes de hipótese.

2. Considere o código abaixo para o carregamento dos dados "iris", na linguagem *Python*.

```
from sklearn import datasets

# Carrega o conjunto de dados
data = datasets.load_iris(as_frame = True)
df_iris = data.frame
df_iris.columns = ["sepal_length", "sepal_width",
"petal_length", "petal_width", "species"]

# Atualiza para os nomes das especies
df_iris["species"] = df_iris["species"].astype(str)
df_iris.loc[df_iris["species"] == "0", "species"] = "setosa"
df_iris.loc[df_iris["species"] == "1", "species"] = "versicolor"
df_iris.loc[df_iris["species"] == "2", "species"] = "virginica"

df_iris.head(4)
```

a) Obtenha as métricas relevantes para a distribuição de cada uma das variáveis (média, desvio-padrão, coeficiente de variação, mediana e quartis).

b) Construa gráficos para avaliar a associação entre cada variável quantitativa e a variável "species".

c) Construa uma matriz de correlações entre as variáveis numéricas e interprete os resultados.

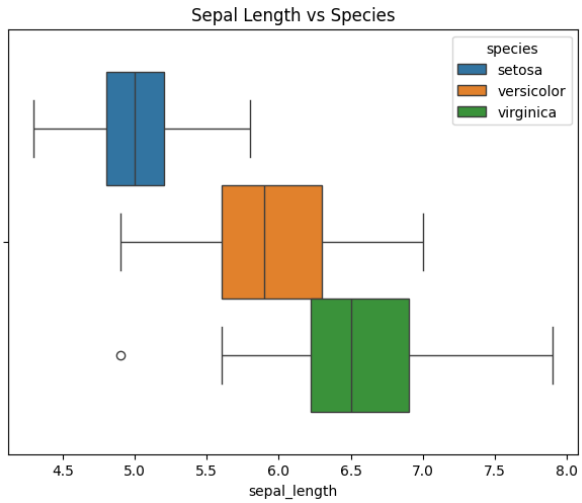
d) Construa gráficos para identificar a associação entre pares das variáveis quantitativas e interprete os resultados.

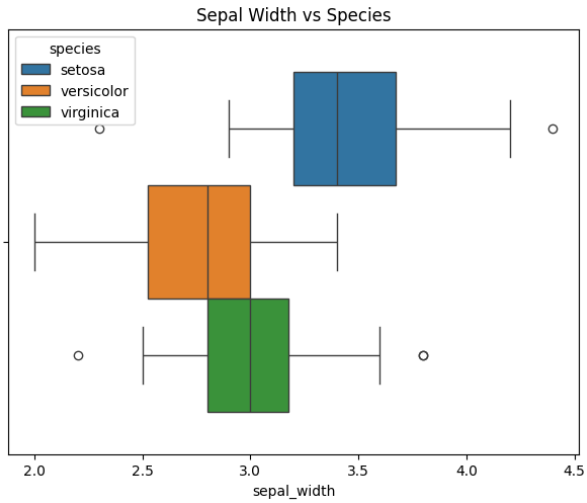
a) Basta utilizar o comando do *Python* "df.describe()".

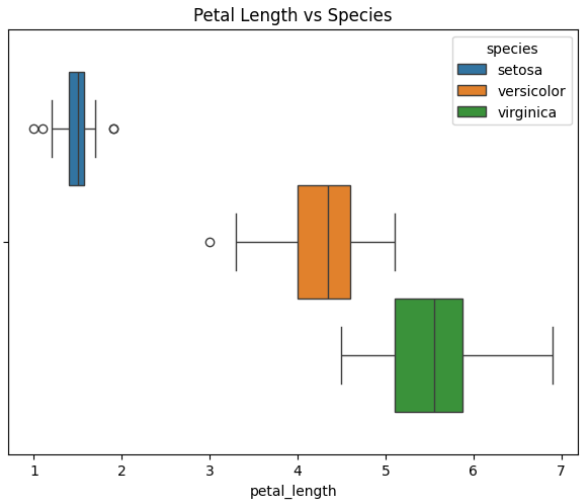
b) Uma possibilidade é a criação de *boxplots*, uma vez que buscamos a associação entre variáveis quantitativas e qualitativas. Um código possível é dado abaixo.

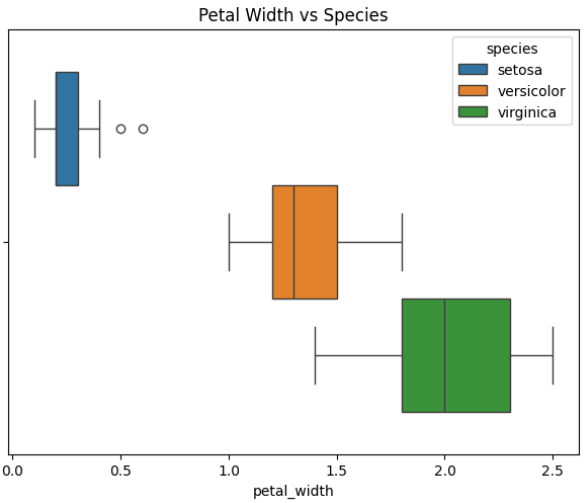
```
fig, ax = plt.subplots(nrows = 2, ncols = 2, figsize = (16,12))

sns.boxplot(x = "sepal_length", hue = "species", data = df_iris, ax = ax[0,0])
ax[0,0].set_title("Sepal Length vs Species")
sns.boxplot(x = "sepal_width", hue = "species", data = df_iris, ax = ax[0,1])
ax[0,1].set_title("Sepal Width vs Species")
sns.boxplot(x = "petal_length", hue = "species", data = df_iris, ax = ax[1,0])
ax[1,0].set_title("Petal Length vs Species")
sns.boxplot(x = "petal_width", hue = "species", data = df_iris, ax = ax[1,1])
ax[1,1].set_title("Petal Width vs Species")
```









c) Uma forma de se construir uma matriz de correlações é dada abaixo

```
import rdatasets as rd
import numpy as np
import pandas as pd
from matplotlib import pyplot as plt
import seaborn as sns

def corrfunc(x, y, **kws):
    corr = np.corrcoef(x, y)[0, 1]
    ax = plt.gca()
    ax.annotate(f'{corr:.2f}', xy=(0.5, 0.5), xycoords=ax.transAxes,
                ha='center', va='center', fontsize=18, color='black')

quantitative_df = df_iris.loc[:, ["sepal_length", "sepal_width",
                                  "petal_length", "petal_width"]]

fig, ax = plt.subplots(figsize=(12, 8))
heatmap = sns.heatmap(quantitative_df.corr(), vmin=-1, vmax=1, annot=True)
plt.show()
```



Percebemos uma forte correlação entre o comprimento da sépala (sepal_length) e o comprimento e largura da pétala (petal_length e petal_width) das flores Íris. Também, temos uma correlação quase perfeita entre a largura (petal_width) e o comprimento das pétalas (petal_length) das flores. Quanto as demais associações, vemos correlações mais fracas e negativas, indicando, por exemplo, que quanto maior a largura da sépala (sepal_width), menor as dimensões da pétala, em média, por exemplo.

d) Uma forma de avaliar os pares de variáveis quantitativas se dá através de um gráfico *pairplot*. Abaixo, temos um código desse gráfico customizado, para que sejam exibidas as correlações na parte triangular acima do grid.

```
def corrfunc(x, y, hue, **kws):
    # Numero de classes
    num_classes = len(hue.unique())

    color_palette = sns.color_palette().as_hex()

    # Para cada classe, calcula as correlacoes
    corrs = []
    for class_value in hue.unique():
        corr = np.corrcoef(x[hue == class_value], y[hue == class_value])[0, 1]
        corrs.append(corr)
    corr_xy = np.corrcoef(x, y)[0, 1]

    ax = plt.gca()
```

```
    # Divide o espaco do grid no numero de classes
    y_positions = np.linspace(0, 1, num_classes + 2)[1:-1]

    for j in range(len(corrs)):
        ax.annotate("{:.2f}".format(corrs[j], hue.unique()[j]), xy=(0.3, y_positions[j]),
        xycoords=ax.transAxes,
                    ha='center', va='center', fontsize=18, color=color_palette[j])

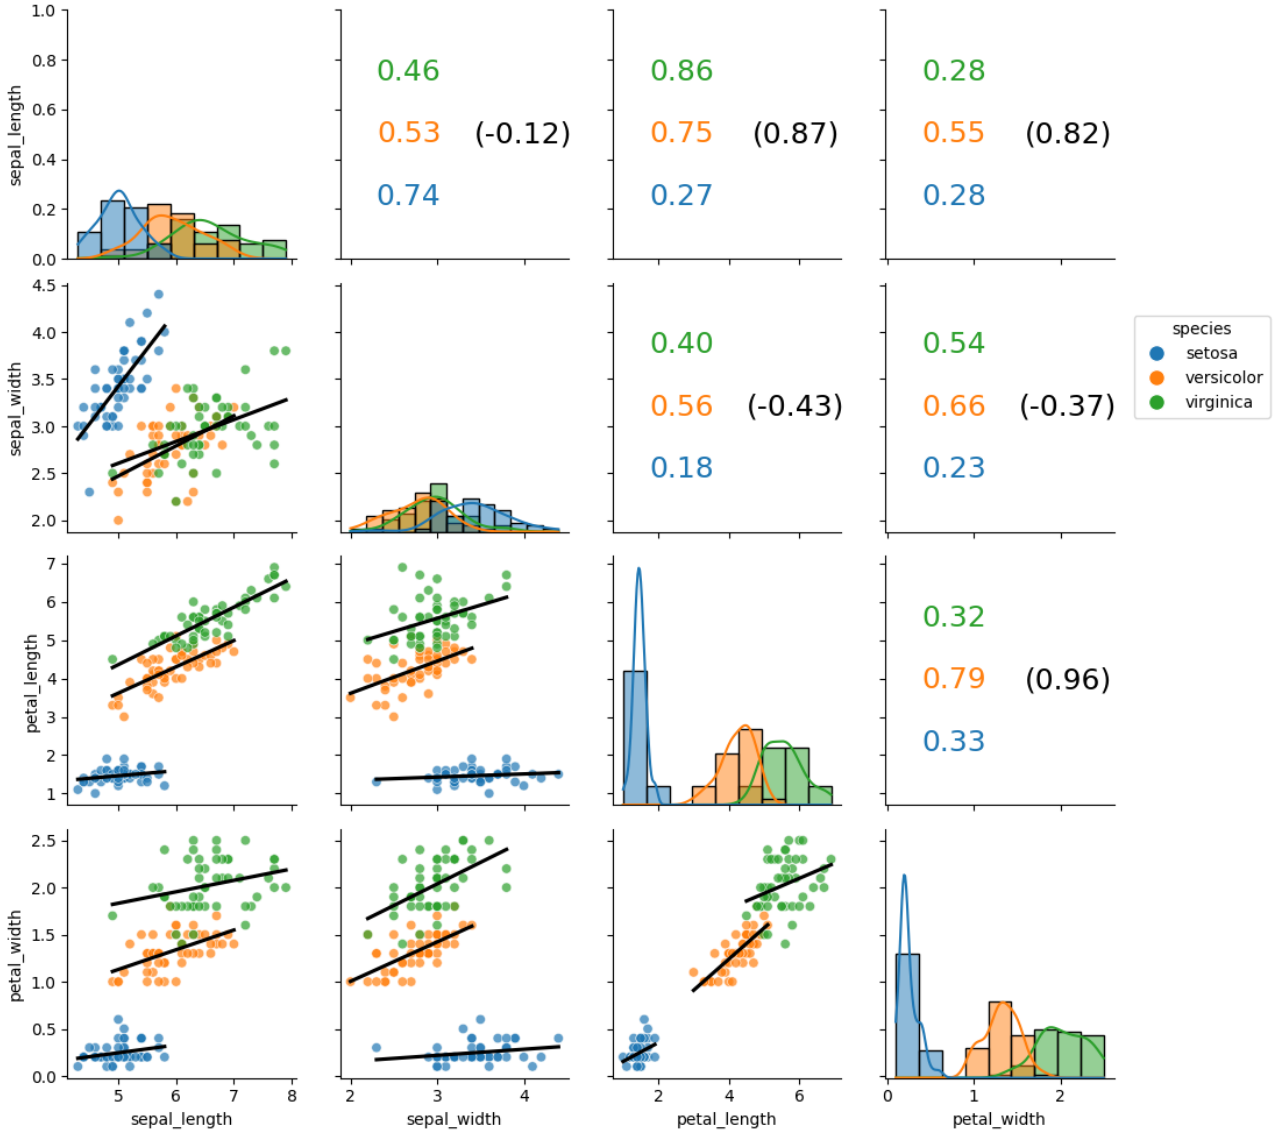
    # Adiciona a correlação geral desconsiderando as classes (em preto)
    ax.annotate("({:.2f})".format(corr_xy, hue.unique()[j]), xy=(0.8, 0.5),
    xycoords=ax.transAxes,
                ha='center', va='center', fontsize=18, color="black")

g = sns.PairGrid(df_iris, hue = "species")
g.map_lower(sns.scatterplot, alpha=0.7)
g.map_lower(sns.regplot, scatter=False, ci=None, line_kws={"color": "black"})
g.map_diag(sns.histplot, kde=True)
g.map_upper(corrfunc)

# Adiciona a legenda ao grid manualmente
handles = [plt.Line2D([0], [0], marker='o', color='w',
                      markerfacecolor=sns.color_palette()[i], markersize=10,
                      label=species)
           for i, species in enumerate(df_iris["species"].unique())]

plt.legend(handles=handles, title="species", loc="upper left", bbox_to_anchor=(1.05, 2))

plt.show()
```



A partir dos gráficos, podemos confirmar o que foi visto na matriz de correlações do item (c). De fato, temos uma relação linear relativamente satisfatória entre todos os pares de variáveis, com exceção do par (largura da sépala, comprimento da sépala), que apresenta uma correlação muito baixa.

Um ponto muito interessante que pode ser observado é o fato de que em alguns casos, como a relação entre largura da sépala e comprimento da pétala, as correlações dentro de cada classe são positivas (0.4, 0.56 e 0.18), mas a correlação geral de todas as observações em uma única classe é negativa. Chamamos esse comportamento contrário de Paradoxo de Simpson. Esse problema nos alerta o quanto é importante uma análise exploratória de dados cautelosa. Neste caso, se não consideramos a espécie da flor, podemos tirar conclusões completamente diferentes do que se consideramos. As perguntas e respostas da análise exploratória devem estar claras para evitar possíveis mau entendidos, como esse.

3. O código abaixo carrega uma base de dados de filmes da Netflix com as variáveis pré-tratadas (mais informações em `https://www.kaggle.com/datasets/shivamb/netflix-shows`).

```
import pandas as pd
```

```
df = pd.read_csv("https://raw.githubusercontent.com/cibelerusso/" +
           "Datasets/main/netflix_titles_dataset.csv")
df.head(3)
```

Com base neste conjunto de dados, construa tabelas de frequência relativa, gráficos de barras e de mosaico para avaliar a associação entre as variáveis "country" (país de origem do filme) e "rating" (classificação indicativa do filme: 14, 18 ou L). Existem indícios que nos apontem uma possível associação?

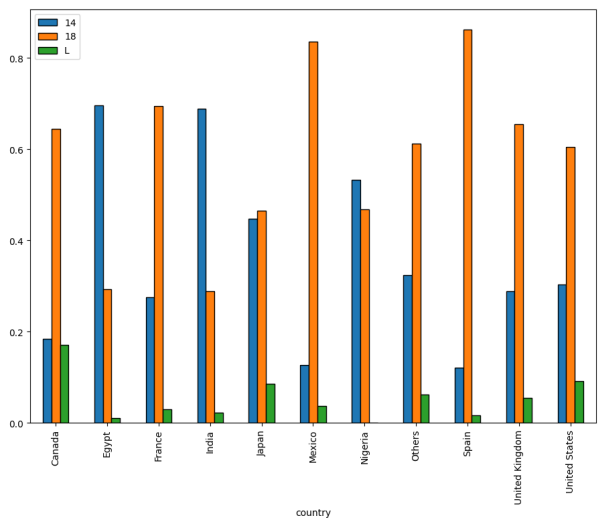
RESOLUÇÃO EM PYTHON:

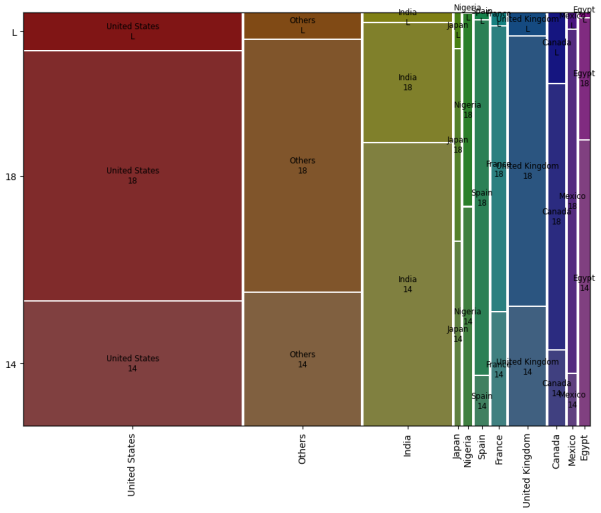
```
import pandas as pd
from matplotlib import pyplot as plt
from statsmodels.graphics.mosaicplot import mosaic

df = pd.read_csv("https://raw.githubusercontent.com/cibelerusso/" +
           "Datasets/main/netflix_titles_dataset.csv")
tab = pd.crosstab(index = df["country"], columns = df["rating"], normalize = 0)

tab.plot.bar(edgecolor = "black")
plt.legend (loc = "upper left")
plt.show()

fig, ax = plt.subplots(figsize = (12, 8))
mosaic(df, ["country", "rating"], ax = ax)
ax.set_xticklabels(df["country"].unique().tolist(), rotation = 90)
plt.show()
```





Como podemos ver na imagem acima, o padrão das barras correspondentes à classificação etária muda completamente de um país para o outro. Ainda, pelo gráfico de mosaico fica evidente que não temos um padrão das variáveis em "grid", nos levando a acreditar ainda mais que existe uma associação entre o país e a distribuição das classificações etárias dos seus filmes. Como um exemplo, vemos que, de fato, a Índia e o Egito produzem majoritariamente filmes para um público a partir de 14 anos de idade, enquanto no México e Espanha, em sua maioria, os filmes são destinados apenas a maiores de 18 anos.

4. Com relação à análise exploratória de dados, considere as seguintes afirmações:

I. Os gráficos de dispersão são úteis para identificar associação entre variáveis quantitativas.

II. A maior vantagem dos gráficos de *boxplot* é o fato de que é possível identificar diferenças estatisticamente significantes apenas ao olhar a figura.

III. O coeficiente de correlação de Spearman quantifica a associação linear entre duas variáveis qualitativas

IV. Os *outliers* não devem ser retirados do conjunto de dados sem uma boa justificativa para tal.

V. O coeficiente de variação é uma métrica adimensional da distribuição dos dados

VI. Para distribuições unimodais (densidade com um ponto de máximo apenas) assimétricas a direita, temos que moda $<$ mediana $<$ média.

As alternativas corretas são

a) IV, e VI apenas

b) II e III e V

c) I, V e VI

d) I, IV, V e VI

e) todas as alternativas

A resposta correta é a letra (d). De fato, II está errado, pois a significância estatística requer testes de hipótese e III está errado, já que a associação linear é quantificada pelo coeficiente de correlação linear de Pearson, não se Spearman.

5. Em um jogo de RPG. suponha o lançamento de um dado honesto de 20 faces, Considere os seguintes eventos:

- A: o número é maior que 5,
- B: o número é primo,
- C: o é par,

a) Obtenha a probabilidade dos eventos $A \cap B$, $A \cap C$, $B \cap C$ e $A \cap B \cap C$.

b) Supondo que, caso o jogador obtenha um resultado menor ou igual a 4, seu personagem morre, qual a probabilidade de que ele fique vivo, dado que ocorreu o evento A?

c) Supondo que, caso o jogador obtenha um resultado menor ou igual a 4, seu personagem morre, qual a probabilidade de que ele fique vivo, dado que ocorreu o evento B?

a) Temos que $\Omega = \{1, 2, 3, 4, 5, 6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19, 20\}$ **e**

$$A = \{6, 7, 8, 9, 10, 11, 12, 13, 14, 15, 16, 17, 18, 19, 20\},$$
$$B = \{2, 3, 5, 7, 11, 13, 17, 19\},$$
$$C = \{2, 4, 6, 8, 10, 12, 14, 16, 18, 20\}.$$

As interseções serão, portanto,

$$\begin{aligned} A \cap B &= \{7, 11, 13, 17, 19\}, \\ A \cap C &= \{6, 8, 10, 12, 14, 16, 18, 20\}, \\ B \cap C &= \{2\}, \\ A \cap B \cap C &= \{\} = \emptyset. \end{aligned}$$

Como o dado é honesto, obtemos as probabilidades como

$$\begin{aligned} P(A \cap B) &= \frac{\#(A \cap B)}{\#\Omega} = \frac{5}{20} = \frac{1}{4}, \\ P(A \cap C) &= \frac{\#(A \cap C)}{\#\Omega} = \frac{8}{20} = \frac{2}{5}, \\ P(B \cap C) &= \frac{\#(B \cap C)}{\#\Omega} = \frac{1}{20}, \\ P(A \cap B \cap C) &= \frac{0}{20} = 0 \end{aligned}$$

b) Dado que ocorreu o evento A, já sabemos que o número obtido é maior que 5, portanto, a probabilidade do personagem viver é igual a 1.

c) Sendo $D = \Omega - \{1, 2, 3, 4\}$, obtemos que

$$D \cap B = \{5, 7, 11, 13, 17, 19\}.$$

Assim, a probabilidade desejada pode ser obtida como

$$P(D|B) = \frac{P(D \cap B)}{P(B)} = \frac{\#(D \cap B)/20}{\#B/20} = \frac{6}{8} = \frac{3}{4}.$$

6. Uma empresa procura investigar três perfis propagadores de notícias falsas em uma rede social. No geral, 75% das informações publicadas pelo perfil A são falsas, diferente dos 30% e 50% referentes aos perfis B e C, respectivamente. Nos últimos 6 meses, o perfil A fez um total de 85 postagens, o perfil B fez 150, enquanto que o perfil C fez 230. O investigador garante que uma nova notícia falsa foi originada em um desses perfis. Qual a probabilidade de que essa notícia seja dos perfis A, B e C, respectivamente?

Considerando os eventos

$$\begin{aligned} A: &\ \textbf{a notícia veio do perfil A}, \\ B: &\ \textbf{a notícia veio do perfil B}, \\ C: &\ \textbf{a notícia veio do perfil C}, \\ F: &\ \textbf{a notícia é falsa} \ . \end{aligned}$$

Como a notícia certamente é de um desses perfis, temos que a soma das probabilidades de A, B e C deve ser 1, já que não são considerados outros perfis externos. Assim,

$$\begin{aligned} P(A) &= \frac{85}{85 + 150 + 230} = \frac{85}{465} = 0.1828, \\ P(B) &= \frac{150}{465} = 0.3226, \\ P(C) &= \frac{85}{465} = 0.4946. \end{aligned}$$

Também temos que $P(F|A) = 0.75$, $P(F|B) = 0.3$ e $P(F|C) = 0.5$. Pelo Teorema da probabilidade total, podemos obter a probabilidade da notícia ser falsa, uma vez que A, B e C representam uma partição do espaço (suas probabilidades somam 1). Assim,

$$P(F) = P(F|A)P(A) + P(F|B)P(B) + P(F|C)P(C) = 0.4812.$$

Finalmente, pela regra de Bayes,

$$\begin{aligned}
P(A|F) &= \frac{P(F|A)P(A)}{P(F)} = \frac{0.75 \cdot 0.1828}{0.4812} = 0.2849, \\
P(B|F) &= \frac{P(F|A)P(B)}{P(F)} = 0.2011, \\
P(C|F) &= \frac{P(F|C)P(C)}{P(F)} = 0.5139.
\end{aligned}$$

7. Considere o seguinte jogo envolvendo o lançamento de moedas. Uma moeda justa é lançada repetidamente até que seja observada uma "coroa". Supondo que nos lançamentos foi observado "cara" por $k \geq 0$ lançamentos, então o jogador recebe como recompensa de 2^{k+1} reais. Ou seja, se os lançamentos forem dados por (cara, cara, coroa), a recompensa é dada por $2^3 = 8$ reais. De fato, caso ocorra "coroa" no primeiro lançamento, o jogador recebe 2 reais.

a) Descreva o espaço amostral, Ω do experimento.

b) Obtenha a função massa de probabilidade para a recompensa do jogador

c) Calcule o valor esperado da recompensa do jogador

d) O problema acima é conhecido como Paradoxo de São Petesburgo. Com base nos resultados obtidos acima, qual uma possível motivação para o nome "paradoxo"?

a) $\Omega = \{(\textbf{coroa}), (\textbf{cara}, \textbf{coroa}), (\textbf{cara}, \textbf{cara}, \textbf{coroa}), (\textbf{cara}, \textbf{cara}, \textbf{cara}, \textbf{coroa}), \cdots\}$

b) Considerando uma moeda justa, seja X : Valor ganho no jogo. Então veja que

$$\begin{aligned}
P(X = 2) &= P(\{(\textbf{coroa})\}) = \frac{1}{2} \\
P(X = 4) &= P(\{(\textbf{cara}, \textbf{coroa})\}) = \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4} \\
P(X = 8) &= P(\{(\textbf{cara}, \textbf{cara}, \textbf{coroa})\}) = \frac{1}{8} \\
&\vdots
\end{aligned}$$

Assim, a função massa de probabilidade para a recompensa, X, é dada por $p(x) = 1/x$.

c) Com base na f.m.p. derivada no item (b),

$$E[X] = 2P(X = 2) + 4P(X = 4) + 8P(X = 8) = 2 \cdot \frac{1}{2} + 4 \cdot \frac{1}{4} + 8 \cdot \frac{1}{8} + \cdots = 1 + 1 + 1 + \cdots = \infty$$

d) O nome paradoxo se vem do fato de que, mesmo tendo um jogo com regras tão simples, obtemos uma recompensa esperada igual a infinito. Além disso, em um cenário da vida real, este jogo não garante chances muito boas de lucro. Suponha, por exemplo, que há um valor de 8 reais para jogar. Sendo assim, embora a esperança do ganho seja teoricamente infinita, a probabilidade de que esses 8 reais sejam recuperados é de $1/8 = 0.125$, o que não parece ser uma probabilidade vantajosa para o jogador.

8. Com relação a variáveis aleatórias (v.a.'s), classifique as seguintes afirmações em verdadeiro (V) e falso (F), justificando caso seja falso.

(V) A probabilidade de que uma variável aleatória contínua, X, seja igual a 2 é sempre igual a zero. (F) Se X é uma v.a. discreta, suas probabilidades são descritas pela função densidade de probabilidade, enquanto que se X é contínua, utilizamos a função massa de probabilidade.
Se X é discreta, tem probabilidades descritas pela função massa de probabilidade e se X é contínua, pela função densidade de probabilidade.
(V) É possível que uma variável aleatória discreta assuma infinitos possíveis valores. (V) A função de distribuição acumulada de uma v.a. pode ser obtida por uma integral, no caso contínuo e um somatório, no caso discreto. (F) A esperança de uma variável aleatória sempre existe e é finita.
Considere o exemplo do exercício 7.
(F) Quando $E[X^2] < E[X]^2$, a variável X apresenta variância negativa.
De fato, é impossível que $E[X^2] < E[X]^2$ e, por isso, a variância nunca é negativa. (Caso tenha interesse em aprofundar, este resultado pode ser provado matematicamente através de uma relação chamada de Desigualdade de Jensen)
(V) Se $X > 1$, então $E[X] > 1$.

9. Seja X variável contínua com densidade

$$f(x) = \lambda e^{-\lambda x}.$$

Calcule a sua função densidade acumulada e a esperança de X.

A função densidade acumulada pode ser obtida fazendo

$$F(x) = \int_0^x f(u)du = \int_0^x \lambda e^{-\lambda u} du = \left[-e^{-\lambda u}\right]_{u=0}^{u=x} = 1 - e^{-\lambda x}.$$

A esperança pode ser calculada similarmente fazendo

$$E[X] = \lambda \int_0^\infty x e^{-\lambda x} dx.$$

Integrando por partes, com $u = x$, $du = dx$, $dv = e^{-\lambda x}dx$ e $v = -e^{-\lambda x}/\lambda$, obtemos

$$\begin{aligned} E[X] &= \lambda \left[\frac{1}{\lambda} x e^{-\lambda x} \Big|_{x=0}^{x\to\infty} + \frac{1}{\lambda} \int_0^\infty e^{-\lambda x} \right] \\ &= \lambda \left[\frac{1}{\lambda} \int_0^\infty e^{-\lambda x} dx \right] \\ &= \int_0^\infty e^{-\lambda x} dx \\ &= -\frac{1}{\lambda} \left[e^{-\lambda x} \right]_{x=0}^{x\to\infty} = \frac{1}{\lambda}. \end{aligned}$$

10. Seja X variável discreta que assume os valores $0, 1, 2, 3$ e 4 com probabilidades 0.2, 0.3, 0.3, 0.05 e 0.15, respectivamente. Obtenha a esperança e a variância de X.

$$
\begin{aligned}
E[X] &= \sum_x xP(X = x) = 0 \cdot 0.2 + 1 \cdot 0.3 + 2 \cdot 0.3 + 3 \cdot 0.05 + 4 \cdot 0.15 = 1.65, \\
E[X^2] &= \sum_x x^2 P(X = x) = 0^2 \cdot 0.2 + 1^2 \cdot 0.3 + 2^2 \cdot 0.3 + 3^2 \cdot 0.05 + 4^2 \cdot 0.15 = 4.35, \\
\mathrm{Var}[X] &= E[X^2] - E[X]^2 = 4.35 - (1.65)^2 = 1.6275.
\end{aligned}
$$