Lista de Exercícios - Quinzena 2
Módulo 1: Estatística para Ciência de Dados
Professora: Cibele Russo
Monitor: Natan Hilário

1. Em uma bolsa de valores, uma métrica para quantificar o retorno entre dois tempos é dada por x_{t+1}/x_t, em que x_t representa o valor da ação no tempo t. Suponha que os retornos de uma ação seguem a distribuição triangular, cuja densidade é dada por

$$f(x) = \begin{cases} \frac{x}{\theta^2} + \frac{1}{\theta}, & \text{se } -\theta < x \leq 0, \\ -\frac{x}{\theta^2} + \frac{1}{\theta}, & \text{se } 0 < x < \theta \end{cases}$$

Suponha que, em um período de instabilidade, o desvio-padrão estimado em tempo real dos retornos tenha alcançado um valor igual a 8. Nessa época, podemos dizer que o intervalo de variação dos retornos dessa ação era dado por

a) $\left(-2\sqrt{2}; 2\sqrt{2}\right)$.

b) $(-2; 2)$.

c) $(-8; 8)$.

d) $\left(-4\sqrt{6}; 4\sqrt{6}\right)$.

e) $\left(-8\sqrt{6}; 8\sqrt{6}\right)$.

2. Em um casal, suponha que o faturamento mensal (em reais) X, da primeira pessoa, tenha uma distribuição normal com média $\mu_1 = 2500$ e variância $\sigma_1^2 = 500^2$ e o faturamento mensal (em reais) Y, da segunda pessoa, tenha distribuição normal com média $\mu_2 = 1600$ com variância $\sigma_2^2 = 150^2$. Considerando que X e Y são independentes, determine a probabilidade de que em um mês, o casal obtenha um faturamento maior que R$4500,00.

3. Classifique as seguintes afirmações em verdadeiro (V) e falso (F), justificando caso seja falso.

( ) A distribuição de Poisson modela o número de "sucessos" em um total de n experimentos.

( ) Se duas variáveis aleatórias X e Y são independentes, então $\text{Cov}(X, Y) = 0$.

( ) O Teorema do Limite Central (TLC) garante que a distribuição da média amostral $\overline{X}$ de uma amostra aleatória $X_1, \ldots, X_n$ com média e variância finitas tende a uma distribuição normal quando $n \to \infty$.

( ) $\text{Cov}[X, c] = c\sigma_X$, em que σ_X é o desvio padrão de X e c é uma constante.

( ) Se X e Y são duas variáveis aleatórias independentes, então

$$P(X \leq x, Y \leq y) = P(X \leq x)P(Y \leq y).$$

( ) A distribuição que melhor descreve as probabilidades de cada face em um dado honesto é a distribuição Binomial$(n = 6, p = 1/6)$.

4. Considere uma amostra aleatória de tamanho n, $X_1, \ldots, X_n$ da distribuição Exponencial(λ), ou seja, com densidade

$$f(x) = \lambda e^{-\lambda x}.$$

Chamamos de a n-ésima estatística de ordem, denotando-a por $X_{(n)}$ a maior observação da amostra, ou seja

$$X_{(n)} = \max\{X_1, \cdots, X_n\}.$$

Obtenha a função densidade de probabilidade acumulada para a variável aleatória $X_{(n)}$. Calcule $P(X_{(n)} > 1)$.

5. Suponha que X é uma variável aleatória que representa o tempo de um determinado dia, assumindo os valores

$$X = \begin{cases} 0, & \text{se o dia estiver ensolarado,} \\ 1, & \text{se chover,} \\ 2, & \text{se ocorrer uma tempestade.} \end{cases}$$

Considere que João planeja sair de casa no dia atual e assuma a variável aleatória Y, que assume

$$Y = \begin{cases} 0, & \text{se João saiu de casa com seu guarda-chuva,} \\ 1, & \text{se João se esqueceu de levar o guarda-chuva.} \end{cases}$$

Abaixo, são dadas as probabilidades conjuntas associadas a ambas as variáveis X e Y.

$Y \backslash X$	0	1	2
0	0.1	0.15	0.1
1	0.25	0.2	0.2

Suponha que a tristeza de João com seu dia seja dada pela variável aleatória $T = YX^2 + X$.

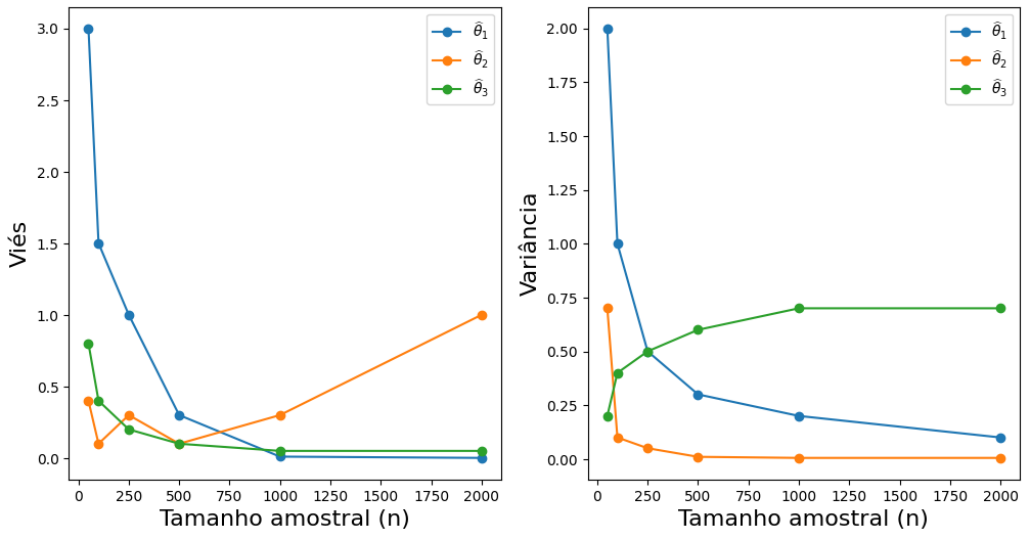
a) As variáveis X e Y são independentes?

b) Obtenha a função massa de probabilidade para a tristeza de João no dia.

c) Calcule o valor esperado para a tristeza de João.

d) Calcule a correlação entre X e Y.

6. Em um problema de inferência estatística, foram realizadas simulações para avaliar a performance de três estimadores diferentes para o parâmetro θ, denotados por $\widehat{\theta}_1$ e $\widehat{\theta}_2$ e $\widehat{\theta}_3$. Abaixo são dados gráficos para o viés e a variância de cada estimador para diferentes tamanhos da amostra.



Com base nos resultado abaixo, considere as alternativas

I. O estimador $\widehat{\theta}_1$ parece ser consistente.

II. O estimador $\widehat{\theta}_3$ parece ser consistente.

III. Embora $\widehat{\theta}_2$ tenha um viés crescente, sua baixa variância o torna o melhor dos três estimadores (menor erro quadrático médio).

IV. O estimador $\widehat{\theta}_3$ parece ser assintoticamente não viesado

V. A variância do $\widehat{\theta}_3$ se estabiliza para amostras grandes, sendo um traço desejável.

As alternativas corretas são

a) I, II, III apenas.

b) I, II, IV e V apenas.

c) I e IV apenas.

d) II e IV apenas.

e) Todas.

7. Considere uma amostra aleatória $X_1, \cdots, X_n$ cuja distribuição tem função densidade de probabilidade dada por

$$f(x) = \theta x^{\theta-1}, \quad 0 < x < 1, \quad \theta > 0.$$

Obtenha o estimador de máxima verossimilhança para θ.

8. Em um estudo de salinidade da água de um rio que sofre influência de marés, os cientistas divulgaram que o intervalo com 95% para a salinidade da água era dado por $(3.1256; 3.8744)$ em g/L (gramas de sal por litro). Sabendo que o resultado foi obtido utilizando-se um total de 20 amostras, obtenha

a) A média e desvio padrão amostrais observados pelos cientistas.

b) Calcule qual seria o intervalo de confiança com nível 99% de confiança. Este intervalo é maior ou menor que o intervalo 95%? Argumente o motivo.

c) Qual deveria ser o tamanho amostral para que o comprimento do intervalo com confiança de 95% fosse inferior a 0.1 g/L?

9. Com relação aos testes de hipótese, classifique as seguintes afirmações em verdadeiro (V) e falso (F), justificando caso seja falso.

( ) Rejeitamos a hipótese nula, caso a estatística do teste esteja fora da região crítica.

( ) O poder do teste é dado por $1 - \tau$, em que τ é a probabilidade do erro Tipo II.

( ) Quanto maior o nível de significância, maior a probabilidade de rejeitar H_0, sendo esta falsa.

( ) O p-valor representa a probabilidade de se observar uma amostra similar, considerando que H_0 é verdadeira.

( ) É impossível a elaboração de um teste de hipóteses sem erros.

( ) O nível de significância representa a probabilidade do erro Tipo I.

( ) O teste T para amostras independentes não requer uma distribuição específica para os dados.

( ) O teste ANOVA requer que os grupos comparados tenham mesma variância

10. Ao aplicarmos testes da ANOVA para identificar diferenças entre três ou mais grupos em um conjunto de dados, quando rejeitamos a hipótese nula de igualdade de médias, não é recomendado a aplicação de testes T dois a dois entre os grupos para identificar onde essa diferença pode ser observada. Usualmente, é realizado um teste chamado teste de Tukey. Argumente possíveis razões para as quais os testes T dois a dois não seriam uma boa alternativa. (**Dica:** Suponha que temos três grupos. Qual a probabilidade do erro Tipo I quando os testes dois a dois tem nível de significância 5%?)

11. Uma empresa de aluguel de carros deseja investigar se o tipo de carro alugado influencia na duração do aluguel. Um experimento foi conduzido por uma semana em um local específico. Foram selecionados aleatoriamente 10 contratos para cada modelo de carro. Os resultados são mostrados na tabela a seguir.

Tipo de carro	Observações									
Subcompacto	3	5	3	7	6	5	3	2	1	6
Compacto	1	3	4	7	5	6	3	2	1	7
Médio	4	1	3	5	7	1	2	4	2	7
Grande	4	6	8	6	11	4	5	8	3	8

a) Verifique se as condições do teste ANOVA são satisfeitas pelos dados. (normalidade e homoscedasticidade de variâncias). Aplique testes de hipótese se possível.

b) Conduza uma análise descritiva e uma análise de variâncias em Python (ou em R) para concluir se existem evidências que contribuem para a hipótese de que o tipo de carro influencia na duração do contrato.