Lista de Exercícios com GABARITO - Quinzena 2
Módulo 1: Estatística para Ciência de Dados
Professora: Cibele Russo
Monitor: Natan Hilário

1. Em uma bolsa de valores, uma métrica para quantificar o retorno entre dois tempos é dada por x_{t+1}/x_t, em que x_t representa o valor da ação no tempo t. Suponha que os retornos de uma ação seguem a distribuição triangular, cuja densidade é dada por

$$f(x) = \begin{cases} \frac{x}{\theta^2} + \frac{1}{\theta}, & \text{se } -\theta < x \leq 0, \\ -\frac{x}{\theta^2} + \frac{1}{\theta}, & \text{se } 0 < x < \theta. \end{cases}$$

Suponha que, em um período de instabilidade, o desvio-padrão estimado em tempo real dos retornos tenha alcançado um valor igual a 8. Nessa época, podemos dizer que o intervalo de variação dos retornos dessa ação era dado por

a) $\left(-2\sqrt{2}; 2\sqrt{2}\right)$.

b) $(-2; 2)$.

c) $(-8; 8)$.

d) $\left(-4\sqrt{6}; 4\sqrt{6}\right)$.

e) $\left(-8\sqrt{6}; 8\sqrt{6}\right)$.

Para respondermos a essa questão, devemos calcular o desvio padrão da distribuição sugerida (Se você não está familiarizado(a) com o cálculo de integrais, não tem problema! Basta inserir a integral no `https://www.wolframalpha.com/`). Temos

$$\begin{aligned} E[X] &= \int_{-\theta}^{0} x \left[\frac{x}{\theta^2} + \frac{1}{\theta}\right] dx + \int_{0}^{\theta} x \left[-\frac{x}{\theta^2} + \frac{1}{\theta}\right] dx \\ &= \int_{-\theta}^{0} \left[\frac{x^2}{\theta^2} + \frac{x}{\theta}\right] dx + \int_{0}^{\theta} \left[-\frac{x^2}{\theta^2} + \frac{x}{\theta}\right] dx. \end{aligned}$$

Integrando o primeiro e segundo termos,

$$\begin{aligned} \int_{-\theta}^{0} \left[\frac{x^2}{\theta^2} + \frac{x}{\theta}\right] dx &= \frac{1}{3\theta^2}\left[x^3\right]_{-\theta}^{0} + \frac{1}{2\theta}\left[x^2\right]_{-\theta}^{0} \\ &= \frac{1}{3\theta^2}\left[0 - (-\theta^3)\right] + \frac{1}{2\theta}\left[0 - (\theta^2)\right] \\ &= \frac{\theta}{3} - \frac{\theta}{2} = -\frac{\theta}{6}, \\ \int_{0}^{\theta} \left[-\frac{x^2}{\theta^2} + \frac{x}{\theta}\right] dx &= -\frac{1}{3\theta^2}\left[x^3\right]_{0}^{\theta} + \frac{1}{2\theta}\left[x^2\right]_{0}^{\theta} \\ &= -\frac{1}{3\theta^2}\left[\theta^3 - 0\right] + \frac{1}{2\theta}\left[\theta^2 - 0\right] \\ &= -\frac{\theta}{3} + \frac{\theta}{2} = \frac{\theta}{6}. \end{aligned}$$

Assim,

$$E[X] = -\frac{\theta}{6} + \frac{\theta}{6} = 0.$$

De fato, ao fazer o gráfico da densidade, vemos que é simétrica em torno do zero. Calculemos o segundo momento.

$$E[X^2] = \int_{-\theta}^{0} \left[\frac{x^3}{\theta^2} + \frac{x^2}{\theta}\right] dx + \int_{0}^{\theta} \left[-\frac{x^3}{\theta^2} + \frac{x^2}{\theta}\right] dx.$$

Novamente, calculando o primeiro e segundo termos

$$\begin{aligned}
\int_{-\theta}^{0} \left[\frac{x^3}{\theta^2} + \frac{x^2}{\theta}\right] dx &= \frac{1}{4\theta^2}\left[x^4\right]_{-\theta}^{0} + \frac{1}{3\theta}\left[x^3\right]_{-\theta}^{0} \\
&= \frac{1}{4\theta^2}\left[0 - (\theta^4)\right] + \frac{1}{3\theta}\left[0 - (-\theta^3)\right] \\
&= -\frac{\theta^2}{4} + \frac{\theta^2}{3} = \frac{\theta^2}{12}, \\
\int_{0}^{\theta} \left[-\frac{x^3}{\theta^2} + \frac{x^2}{\theta}\right] dx &= -\frac{1}{4\theta^2}\left[x^4\right]_{0}^{\theta} + \frac{1}{3\theta}\left[x^3\right]_{0}^{\theta} \\
&= -\frac{1}{4\theta^2}\left[\theta^4 - 0\right] + \frac{1}{3\theta}\left[\theta^3 - 0\right] \\
&= -\frac{\theta^2}{4} + \frac{\theta^2}{3} = \frac{\theta^2}{12}.
\end{aligned}$$

Assim,

$$E[X^2] = \frac{\theta^2}{12} + \frac{\theta^2}{12} = \frac{\theta^2}{6}.$$

Finalmente, a variância será dada por

$$\mathrm{Var}[X] = E[X^2] - E[X]^2 = \frac{\theta^2}{6} - 0^2 = \frac{\theta^2}{6}.$$

Consequentemente, o desvio padrão será igual a $\theta/\sqrt{6}$. Sendo assim, se no período mencionado o desvio padrão era igual a 8, então

$$\frac{\theta}{\sqrt{6}} = 8 \Rightarrow \theta = 8\sqrt{6}.$$

Sendo o intervalo de variação de X, $(-\theta, \theta)$, a resposta correta é a letra E.

2. Em um casal, suponha que o faturamento mensal (em reais) X, da primeira pessoa, tenha uma distribuição normal com média $\mu_1 = 2500$ e variância $\sigma_1^2 = 500^2$ e o faturamento mensal (em reais) Y, da segunda pessoa, tenha distribuição normal com média $\mu_2 = 1600$ com variância $\sigma_2^2 = 150^2$. Considerando que X e Y são independentes, determine a probabilidade de que em um mês, o casal obtenha um faturamento maior que R$4500,00.

Sabemos que a soma de duas variáveis aleatórias que seguem distribuições normais também tem distribuição normal. Neste caso, como X e Y são independentes, temos

$$F = X + Y \sim N(\mu, \sigma^2) = N\left(\mu_1 + \mu_2, \sigma_1^2 + \sigma_2^2\right) = N\left(4100, 272500\right).$$

Deixando em termos da distribuição normal padrão, Z, temos que

$$P(F > 4500) = P\left(\frac{F - \mu}{\sigma} > \frac{4500 - \mu}{\sigma}\right) = P\left(Z > \frac{400}{522,0153}\right) = 1 - P(Z \leq 0,7663).$$

Utilizando o pacote scipy da linguagem Python, obtemos que $P(F > 4500) = 1 - 0.7782 = 0.2218$.

3. Classifique as seguintes afirmações em verdadeiro (V) e falso (F), justificando caso seja falso.

(**F**) A distribuição de Poisson modela o número de "sucessos" em um total de n experimentos.
O número de sucessos em n experimentos na verdade é modelado pela distribuição Binomial. A distribuição de Poisson é usada para dados de contagem no geral.
(**V**) Se duas variáveis aleatórias X e Y são independentes, então $\text{Cov}(X, Y) = 0$.
(**V**) O Teorema do Limite Central (TLC) garante que a distribuição da média amostral $\overline{X}$ de uma amostra aleatória $X_1, \ldots, X_n$ com média e variância finitas tende a uma distribuição normal quando $n \to \infty$.
(**F**) $\text{Cov}[X, c] = c\sigma_X$, em que σ_X é o desvio padrão de X e c é uma constante.
Na verdade, a covariância de uma variável aleatória com uma constante qualquer é sempre igual a zero.
(**V**) Se X e Y são duas variáveis aleatórias independentes, então

$$P(X \leq x, Y \leq y) = P(X \leq x)P(Y \leq y).$$

(**F**) A distribuição que melhor descreve as probabilidades de cada face em um dado honesto é a distribuição Binomial$(n = 6, p = 1/6)$.
Um dado honesto tem suas faces guiadas pela distribuição Uniforme discreta com probabilidade $1/6$**.**

4. Considere uma amostra aleatória de tamanho n, $X_1, \ldots, X_n$ da distribuição Exponencial(λ), ou seja, com densidade

$$f(x) = \lambda e^{-\lambda x}.$$

Chamamos de a n-ésima estatística de ordem, denotando-a por $X_{(n)}$ a maior observação da amostra, ou seja

$$X_{(n)} = \max\{X_1, \cdots, X_n\}.$$

Obtenha a função densidade de probabilidade acumulada para a variável aleatória $X_{(n)}$. Calcule $P(X_{(n)} > 1)$.

A função densidade de probabilidade acumulada da variável $X_{(1)}$ **pode ser escrita como**

$$F_{X_{(n)}}(x) = P(X_{(n)} \leq x) = P\left(\max\{X_1, \cdots, X_n\} \leq x\right).$$

Agora, se o máximo valor observado de $X_1, \ldots, X_n$ **é menor que o valor** x**, certamente, todos os valores** $X_1, \ldots, X_n$ **são menores que** x**. Equivalentemente, se todos os valores são menores que** x**, então o maior deles também será. Sendo assim, podemos dizer que**

$$P\left(\max\{X_1, \cdots, X_n\} \leq x\right) = P(X_1 \leq x, \cdots, X_n \leq x).$$

Como as variáveis $X_1, \ldots, X_n$ **são independentes, temos que**

$$P(X_1 \leq x, \cdots, X_n \leq x) = P(X_1 \leq x) \cdots P(X_n \leq x).$$

Mas cada X_i **tem distribuição Exponencial(**λ**). Sendo assim,** $P(X_i \leq x) = 1 - e^{-\lambda x}$ **para todo** X_i**. Portanto,**

$$P(X_1 \leq x) \cdots P(X_n \leq x) = \prod_{i=1}^{n} \left[1 - e^{-\lambda x}\right] = \left(1 - e^{-\lambda x}\right)^n.$$

Assim, a função densidade acumulada do máximo, $X_{(n)}$ **é dada por**

$$F_{X_{(n)}}(x) = \left(1 - e^{-\lambda x}\right)^n.$$

Finalmente,

$$P(X_{(n)} > 1) = 1 - P(X_{(n)} \leq 1) = 1 - F_{X_{(n)}}(1) = 1 - (1 - e^{-\lambda})^n.$$

5. Suponha que X é uma variável aleatória que representa o tempo de um determinado dia, assumindo os valores

$$X = \begin{cases} 0, & \text{se o dia estiver ensolarado,} \\ 1, & \text{se chover,} \\ 2, & \text{se ocorrer uma tempestade.} \end{cases}$$

Considere que João planeja sair de casa no dia atual e assuma a variável aleatória Y, que assume

$$Y = \begin{cases} 0, & \text{se João saiu de casa com seu guarda-chuva,} \\ 1, & \text{se João se esqueceu de levar o guarda-chuva.} \end{cases}$$

Abaixo, são dadas as probabilidades conjuntas associadas a ambas as variáveis X e Y.

$Y \backslash X$	0	1	2
0	0.1	0.15	0.1
1	0.25	0.2	0.2

Suponha que a tristeza de João com seu dia seja dada pela variável aleatória $T = YX^2 + X$.

a) As variáveis X e Y são independentes?

b) Obtenha a função massa de probabilidade para a tristeza de João no dia.

c) Calcule o valor esperado para a tristeza de João.

d) Calcule a correlação entre X e Y.

a) Para verificar a independência, calculemos as marginais. Obtemos a seguinte tabela de probabilidades

$Y \backslash X$	0	1	2	
0	0.1	0.15	0.1	0.35
1	0.25	0.2	0.2	0.65
	0.35	0.35	0.3	1

Agora,

$$P(X = 0, Y = 0) = 0.1 \qquad \text{e} \qquad P(X = 0)P(Y = 0) = 0.35 \cdot 0.35 = 0.1225.$$

Portanto, X e Y não são independentes.

b) Verificando cuidadosamente todos os casos possíveis das variáveis X e Y, a tristeza de João, T, assume os valores possíveis em $\{0, 1, 2, 6\}$. Agora,

$$\begin{aligned} P(T = 0) &= P(X = 0, Y = 0) + P(X = 0, Y = 1) = 0.35, \\ P(T = 1) &= P(X = 1, Y = 0) = 0.15, \\ P(T = 2) &= P(X = 1, Y = 1) + P(X = 2, Y = 0) = 0.3, \\ P(T = 6) &= P(X = 2, Y = 1) = 0.2. \end{aligned}$$

c) Com base na função massa de probabilidade do item (b), obtemos que

$$E[T] = 0P(T=0) + 1P(T=1) + 2P(T=2) + 6P(T=6) = 1.95.$$

d) Para calcularmos a correlação entre X e Y, calculemos primeiro os desvios-padrão de cada variável:

$$\begin{aligned}
\sigma_X^2 &= E[X^2] - E[X]^2 \\
&= \left[0^2P(X=0) + 1^2P(X=1) + 2^2P(X=2)\right] - \left[0P(X=0) + 1P(X=1) + 2P(X=2)\right]^2 \\
&= 1.55 - 0.95^2 = 0.6475, \\
\sigma_Y^2 &= E[Y^2] - E[Y]^2 \\
&= \left[0^2P(Y=0) + 1^2P(Y=1)\right] - \left[0P(Y=0) + 1P(Y=1)\right]^2 \\
&= 0.65 - 0.65^2 = 0.2275.
\end{aligned}$$

Assim, obtemos os desvios-padrão $\sigma_X = \sqrt{0.6475} = 0.8047$ e $\sigma_Y = \sqrt{0.2275} = 0.477$. Nos resta, obter Cov$[X, Y]$. Para isso, calculamos $E[XY]$, $E[X]$, $E[Y]$

$$\begin{aligned}
E[XY] &= 0P(X=0, Y=0) + 0P(X=0, Y=1) + 0P(X=1, Y=0) \\
&\quad + 0P(X=2, Y=0) + 1P(X=1, Y=1) + 2P(X=2, Y=1) \\
&= 0.6, \\
E[X] &= 0P(X=0) + 1P(X=1) + 2P(X=2) = 0.95, \\
E[Y] &= 0.65.
\end{aligned}$$

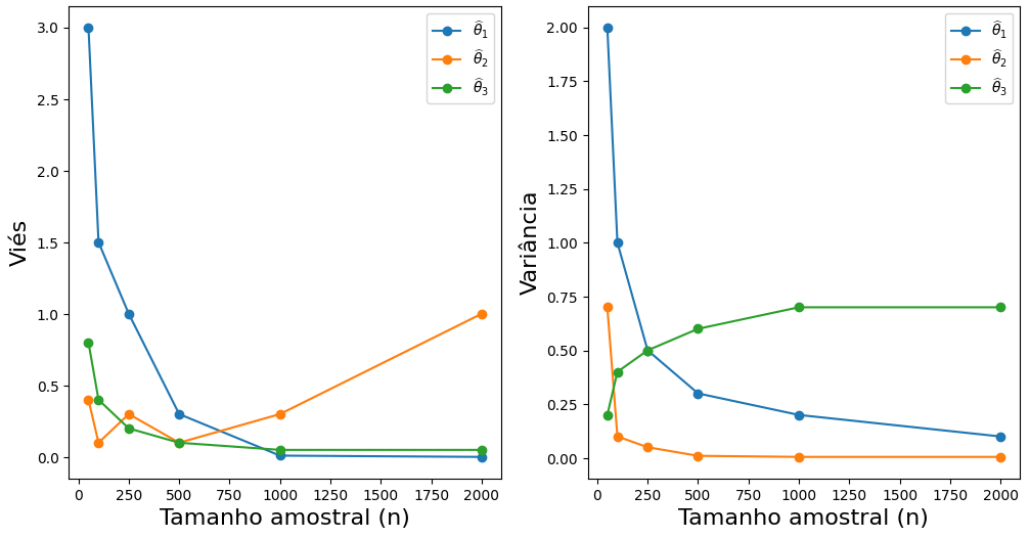
Assim,

$$\text{Cov}[X, Y] = E[XY] - E[X]E[Y] = 0.6 - 0.95 \cdot 0.65 = -0.0175.$$

A correlação entre X e Y será, portanto,

$$\text{Cor}[X, Y] = \frac{\text{Cov}[X, Y]}{\sigma_X \sigma_Y} = -\frac{0.0175}{0.8047 \cdot 0.477} = -0.0456.$$

6. Em um problema de inferência estatística, foram realizadas simulações para avaliar a performance de três estimadores diferentes para o parâmetro θ, denotados por $\widehat{\theta}_1$ e $\widehat{\theta}_2$ e $\widehat{\theta}_3$. Abaixo são dados gráficos para o viés e a variância de cada estimador para diferentes tamanhos da amostra.



Com base nos resultado abaixo, considere as alternativas

I. O estimador $\widehat{\theta}_1$ parece ser consistente.

II. O estimador $\widehat{\theta}_3$ parece ser consistente.

III. Embora $\widehat{\theta}_2$ tenha um viés crescente, sua baixa variância o torna o melhor dos três estimadores (menor erro quadrático médio).

IV. O estimador $\widehat{\theta}_3$ parece ser assintoticamente não viesado

V. A variância do $\widehat{\theta}_3$ se estabiliza para amostras grandes, sendo um traço desejável.

As alternativas corretas são

a) I, II, III apenas.

b) I, II, IV e V apenas.

c) I e IV apenas.

d) II e IV apenas.

e) Todas.

A resposta correta é a (c). De fato, II está errado, já que, embora $\widehat{\theta}_3$ seja assintoticamente não viesado, sua variância não tende a zero, logo não é consistente. III não está correta, já que visualmente $\widehat{\theta}_1$ apresenta um MSE muito menor que $\widehat{\theta}_3$ a medida que n cresce. Finalmente, V não está correta, já que o desejável é que a variância de um estimador se anule a medida que o tamanho amostral cresce, não apenas se estabilize.

7. Considere uma amostra aleatória $X_1, \cdots, X_n$ cuja distribuição tem função densidade de probabilidade dada por

$$f(x) = \theta x^{\theta-1}, \quad 0 < x < 1, \quad \theta > 0.$$

Obtenha o estimador de máxima verossimilhança para θ.

Escrevemos a função de verossimilhança como

$$L(\theta; \boldsymbol{x}) = \prod_{i=1}^{n} f(x_i) = \prod_{i=1}^{n} \theta x_i^{\theta-1} = \theta^n \prod_{i=1}^{n} x_i^{\theta-1}.$$

Tomando o logaritmo natural, temos

$$\ell(\theta; \boldsymbol{x}) = n \log \theta + \sum_{i=1}^{n} (\theta - 1) \log x_i.$$

Derivando o log-verossimilhança acima resulta em

$$\frac{\partial \ell(\theta; \boldsymbol{x})}{\partial \theta} = \frac{n}{\theta} + \sum_{i=1}^{n} \log x_i.$$

Igualando a expressão acima a zero, obtemos que o valor $\widehat{\theta}$ que maximiza a verossimilhança é dado por

$$\widehat{\theta} = -\frac{n}{\sum_{i=1}^{n} \log x_i}.$$

8. Em um estudo de salinidade da água de um rio que sofre influência de marés, os cientistas divulgaram que o intervalo com 95% para a salinidade da água era dado por $(3.1256; 3.8744)$ em g/L (gramas de sal por litro). Sabendo que o resultado foi obtido utilizando-se um total de 20 amostras, obtenha

a) A média e desvio padrão amostrais observados pelos cientistas.

b) Calcule qual seria o intervalo de confiança com nível 99% de confiança. Este intervalo é maior ou menor que o intervalo 95%? Argumente o motivo.

c) Qual deveria ser o tamanho amostral para que o comprimento do intervalo com confiança de 95% fosse inferior a 0.1 g/L?

a) Conhecendo o intervalo de confiança e sabendo que foi usada a suposição de normalidade (se não foi especificado no enunciado, foi considerada a distribuição normal), sabemos que o intervalo é simétrico em torno da média, assim, a média é o ponto médio do intervalo:

$$\bar{x} = \frac{3.1256 + 3.8744}{2} = 3.5.$$

Sabemos que o intervalo de confiança normal é dado por

$$IC[(1-\alpha)\%] = \left(\bar{X} - t_{1-\alpha/2}\frac{S}{\sqrt{n}}; \bar{X} + t_{1-\alpha/2}\frac{S}{\sqrt{n}}\right),$$

assim, conhecendo que $\bar{x} = 3.5$, obtemos o quantil $1-\alpha/2$ da distribuição t-Student com $n-1 = 19$ graus de liberdade ($\alpha = 0.05$), resultando em $t_{0.975} = 2.093$.

```
# Comando em Python para obter o quantil t_{0.975}
from scipy.stats import t
alpha = 0.05
print(t.ppf(1-alpha/2)) # Percent point function (ou função quantil)
```

Temos, portanto, que

$$\bar{x} + t_{0.975}\frac{s}{\sqrt{n}} = 3.8744 \Rightarrow 3.5 + 2.093\frac{s}{\sqrt{20}} = 3.8744.$$

Resolvendo a equação, obtemos o desvio-padrão amostral $s = 0.8$.

b) Supondo o nível de confiança $1-\alpha = 0.99$, temos $\alpha = 0.01$. O quantil associado da distribuição t-Student com $n-1 = 19$ graus de liberdade será $t_{0.995} = 2.8609$. Obtemos, portanto, o intervalo de confiança $(2.9882; 4.0118)$. De fato, o intervalo obtido é maior que o intervalo com 95% de confiança. Isso ocorre justamente pois estamos "requisitando" uma maior confiança, ou seja, gostaríamos de estar mais confiantes que o intervalo contenha o valor real do parâmetro. Sendo assim, é natural que o intervalo seja maior. Pense que um intervalo com 100% de confiança diria que o verdadeiro valor da média está entre $-\infty$ e ∞. Embora essa afirmação nunca estivesse errada, ela é completamente inútil! Por isso possibilitamos a probabilidade de erros.

c) Uma vez conhecidas a média e desvio-padrão amostrais, a expressão do intervalo de confiança é dada por

$$IC[(1-\alpha)\%] = \left(\bar{X} - t_{1-\alpha/2}\frac{S}{\sqrt{n}}; \bar{X} + t_{1-\alpha/2}\frac{S}{\sqrt{n}}\right).$$

Já sabemos do item (a) que $t_{0.975} = 2.093$. Sendo assim, temos que o comprimento do intervalo é dado por

$$\left[\bar{X} + t_{1-\alpha/2}\frac{S}{\sqrt{n}}\right] - \left[\bar{X} - t_{1-\alpha/2}\frac{S}{\sqrt{n}}\right] = 2t_{1-\alpha/2}\frac{S}{\sqrt{n}}.$$

Portanto, basta resolvermos a inequação

$$2t_{0.975}\frac{S}{\sqrt{n}} < 0.1,$$

ou

$$2 \cdot 2.093\frac{0.8}{\sqrt{n}} < 0.1 \Leftrightarrow \frac{3.3488}{\sqrt{n}} < 0.1 \Leftrightarrow \frac{\sqrt{n}}{3.3488} > 10 \Leftrightarrow \sqrt{n} > 33.488.$$

que ocorre quando $n > (33.488)^2 = 1121.4461$. Ou seja, arredondando para inteiros precisaríamos de uma amostra de tamanho $n = 1122$ observações.

9. Com relação aos testes de hipótese, classifique as seguintes afirmações em verdadeiro (V) e falso (F), justificando caso seja falso.
(**F**) Rejeitamos a hipótese nula, caso a estatística do teste esteja fora da região crítica.
Na verdade, rejeitamos H_0 caso a estatística do teste esteja dentro da região crítica.
(**V**) O poder do teste é dado por $1 - \tau$, em que τ é a probabilidade do erro Tipo II.
(**F**) Quanto maior o nível de significância, maior a probabilidade de rejeitar H_0, sendo esta falsa.
O nível de significância é igual à probabilidade de rejeitarmos H_0, sendo ela verdadeira, não falsa.
(**V**) O p-valor representa a probabilidade de se observar uma amostra similar, considerando que H_0 é verdadeira.
(**V**) É impossível a elaboração de um teste de hipóteses sem erros.
(**V**) O nível de significância representa a probabilidade do erro Tipo I.
(**F**) O teste T para amostras independentes não requer uma distribuição específica para os dados.
O teste T para amostras independentes requer que os dados tenham distribuição normal.
(**V**) O teste ANOVA requer que os grupos comparados tenham mesma variância
(**F**) Não é necessário conhecer a distribuição da estatística do teste para a obtenção de uma região crítica satisfatória para o nível de significância, α, fixado.
Sempre devemos conhecer a distribuição da estatística do teste (ou ao menos uma aproximação dela), caso contrário, não é possível obtermos uma região crítica que garanta o nível de significância desejado.

10. Ao aplicarmos testes da ANOVA para identificar diferenças entre três ou mais grupos em um conjunto de dados, quando rejeitamos a hipótese nula de igualdade de médias, não é recomendado a aplicação de testes T dois a dois entre os grupos para identificar onde essa diferença pode ser observada. Usualmente, é realizado um teste chamado teste de Tukey. Argumente possíveis razões para as quais os testes T dois a dois não seriam uma boa alternativa. (**Dica:** Suponha que temos três grupos. Qual a probabilidade do erro Tipo I quando os testes dois a dois tem nível de significância 5%?)

Para responder a essa pergunta, vamos supor que rejeitamos a hipótese de igualdade de médias do teste ANOVA e realizamos testes T dois a dois para identificar

onde existem diferenças estatisticamente significativas entre três grupos, G1, G2 e G3. Para cada teste, fixamos uma probabilidade do erro tipo I em 5%.

Qual é a probabilidade de que em ao menos algum deles, seja cometido o erro do tipo I? Consideramos que "cometer erro tipo I" é um ensaio de Bernoulli com probabilidade $p = 0.05$, assumindo $X_i = 1$ se o erro tipo I foi deito e $X_i = 0$ caso contrário, $i = 1, 2, 3$. A probabilidade de que ao menos um erro foi cometido será

$$P(Y > 0) = P(Y = 1) + P(Y = 2) + P(Y = 3),$$

em que $Y = X_1 + X_2 + X_3$. Sabemos que $Y \sim$ Binomial(0.05). Assim,

$$P(Y > 0) = 1 - P(Y = 0) = 1 - \binom{3}{0}(0.05)^0(1 - 0.05)^{3-0} = 1 - 0.8574 = 0.1426.$$

Ou seja, a probabilidade de erro é muito maior do que gostaríamos de admitir. Não precisamos entrar em detalhes sobre o teste de Tukey, mas nele este problema é considerado, de forma que podemos realizar os testes de forma dois a dois sem que nossa probabilidade de erros do tipo I exceda 0.05.

Neste caso, temos um total de 3 pares de grupos para comparar: G1-G2, G1-G3, G2-G3. E se considerarmos testes T para cada comparação, mas fixarmos níveis de significância $\alpha = 0.05/3 = 0.0167$? Então a probabilidade de que o erro do tipo I seja feito em ao menos um deles é dada por

$$P(Y > 0) = 1 - P(Y = 0) = 1 - \binom{3}{0}(0.0167)^0(1 - 0.0167)^{3-0} = 1 - 0,9508 = 0,0492.$$

Essa abordagem é conhecida como a correção de Bonferroni, e pode ser útil. De fato, reduzimos consideravelmente a probabilidade do erro do Tipo I. Infelizmente, ao reduzirmos o erro Tipo I, aumentamos o erro Tipo II indiretamente. Sendo assim, não necessariamente temos um resultado livre de problemas. Assim, o maior problema com essa abordagem é que ela pode tornar os testes desnecessariamente conservadores com respeito à rejeição da hipótese nula, mas em certos casos, essa correção pode ter interesse prático, principalmente por sua simplicidade.

11. Uma empresa de aluguel de carros deseja investigar se o tipo de carro alugado influencia na duração do aluguel. Um experimento foi conduzido por uma semana em um local específico. Foram selecionados aleatoriamente 10 contratos para cada modelo de carro. Os resultados são mostrados na tabela a seguir.

Tipo de carro	Observações									
Subcompacto	3	5	3	7	6	5	3	2	1	6
Compacto	1	3	4	7	5	6	3	2	1	7
Médio	4	1	3	5	7	1	2	4	2	7
Grande	4	6	8	6	11	4	5	8	3	8

a) Verifique se as condições do teste ANOVA são satisfeitas pelos dados. (normalidade e homoscedasticidade de variâncias). Aplique testes de hipótese se possível.

No código abaixo, para cada tipo de carro diferente, exibimos o valor da média e variância amostrais. Também fazemos um print do teste de Shapiro em cada um

dos tipos, que, caso rejeitado, indica que os dados não seguem uma distribuição normal. Como pode ser visto no output deste código, obtivemos os p-valores 0.5505, 0.3352, 0.259 e 0.5535 para as classes "subcompacto", "compacto", "medio" e "grande", respectivamente. Concluímos que não rejeitamos a hipótese aos níveis de significância usuais (1%, 5%, 2.5%). Para verificar a homocedasticidade das variâncias, usamos o teste de Levene, que obteve um p-valor de 0.9772, nos levando a não rejeitar a hipótese de que os grupos têm mesma variância.

```
# bibliotecas utilizadas
from scipy import stats
import numpy as np
import statsmodels.api as sm
from statsmodels.formula.api import ols
import pandas as pd
# organiza os dados para executar ANOVA
dados = {
"tempo": [3, 5, 3, 7, 6, 5, 3, 2, 1, 6,
          1, 3, 4, 7, 5, 6, 3, 2, 1, 7,
          4, 1, 3, 5, 7, 1, 2, 4, 2, 7,
          4, 6, 8, 6, 11, 4, 5, 8, 3, 8],
"tipo": ["subcompacto"]*10 + ["compacto"]*10 + ["medio"]*10 + \
["grande"]*10
}
df = pd.DataFrame(dados)
df["tempo"] = df["tempo"].astype("float")

tipos = df["tipo"].unique()
for tipo in tipos:
    df_tipo = df.loc[df["tipo"] == tipo, :]
    print("Tipo: {}".format(tipo))
    print("Media: {} ; Variancia: {:.2f}".format(np.mean(df_tipo["tempo"]),
    np.var(df_tipo["tempo"])))
    print("Teste de normalidade:")
    print(stats.shapiro(df_tipo["tempo"]), "\n")

print("Teste para homoscedasticidade:")
print(stats.levene(
    df.loc[df['tipo'] == "subcompacto", "tempo"],
    df.loc[df['tipo'] == "compacto", "tempo"],
    df.loc[df['tipo'] == "medio", "tempo"],
    df.loc[df['tipo'] == "grande", "tempo"]
))
```

b) Conduza uma análise descritiva e uma análise de variâncias em Python (ou em R) para concluir se existem evidências que contribuem para a hipótese de que o tipo de carro influencia na duração do contrato.

Consideramos para o código abaixo que a execução do item (a) tenha sido realizada. Chamamos o teste da ANOVA com a função ols do pacote statsmodels. Observamos o p-valor igual a 0.0413, nos levando a rejeitar a hipótese nula ao nível de significância de 5%.

```
# Construcao de um boxplot
sns.boxplot(df, x = "tipo", y = "tempo")
```

```
plt.show()

# Resultados ANOVA
# Caso tenha problemas com tokenizacao ao copiar o codigo, reescreva "tempo ~tipo"
# usando seu teclado (problemas de caracteres de arquivos PDF)...
model = ols("tempo ~tipo", data = df).fit()
anova_table = sm.stats.anova_lm(model, typ=2) # ou typ=3, para mais fatores
print(anova_table)
```

Quando rejeitemos a hipótese de igualdade entre médias no teste ANOVA, é comum termos o interesse em quais pares de grupos são diferentes e quais podem ser considerados estatisticamente iguais. Uma forma de identificar essas diferenças pode ser realizando testes dois a dois de Tukey. Abaixo, segue o código para a aplicação desses testes. Vemos que, ao nível de significância de 5%, a única comparação dois a dois que resultaria em uma diferença estatisticamente significativa é entre os grupos "grande" e "medio". De fato, quaisquer outros pares não resultaram em diferenças estatisticamente significativas.

```
from statsmodels.stats.multicomp import pairwise_tukeyhsd
tukey = pairwise_tukeyhsd(endog = df["tempo"],
                          groups = df["tipo"],
                          alpha = 0.05)
print(tukey)
```