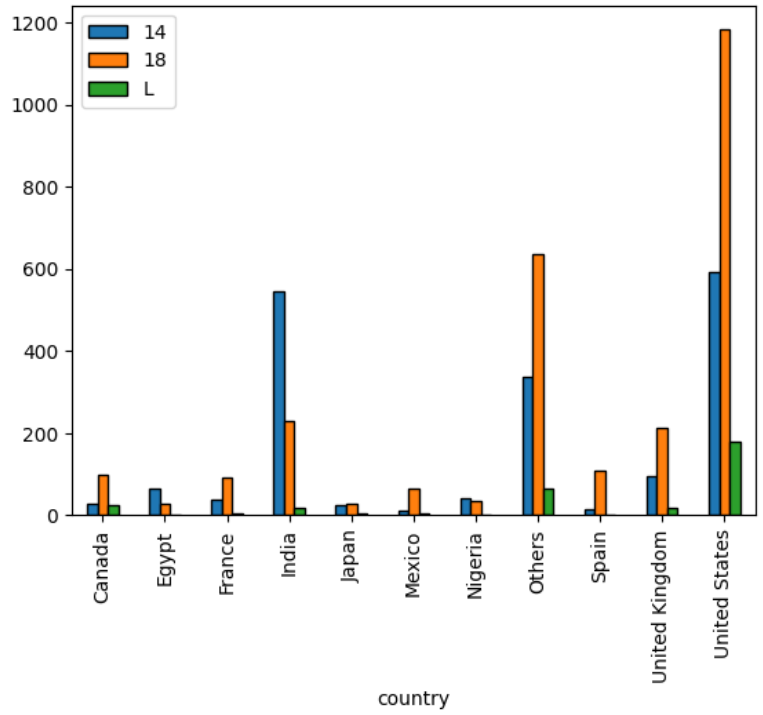
Lista de Exercícios com GABARITO - Quinzena 1
Módulo 2: Métodos estatísticos aplicados
Professora: Cibele Russo
Monitor: Natan Hilário

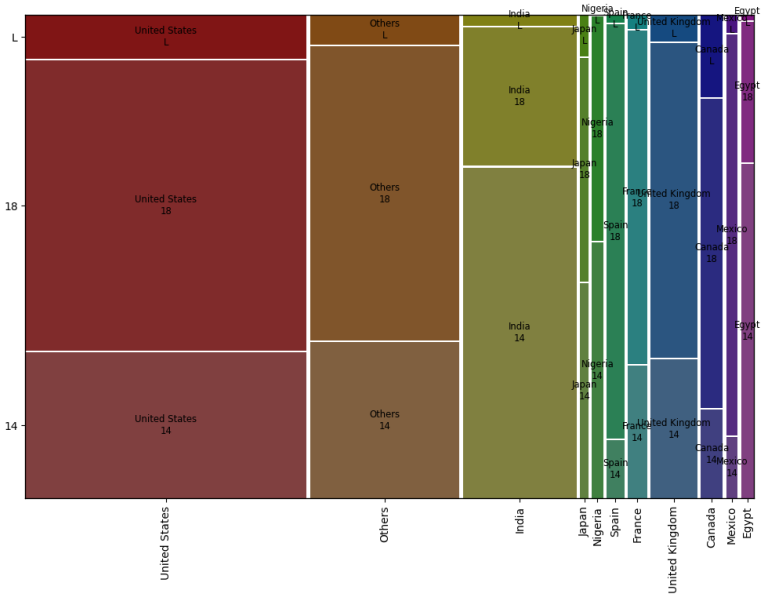
1. O código abaixo, ao ser executado no Google Colab (Python), carrega uma base de dados de filmes da Netflix com as variáveis pré-tratadas. (O dataset original pode ser encontrado em `https://www.kaggle.com/datasets/shivamb/netflix-shows`)

```
import pandas as pd
pd.read_csv("https://raw.githubusercontent.com/cibelerusso/" +
            "Datasets/main/netflix_titles_dataset.csv")
df.head(3)
```

Com base neste conjunto de dados, construa gráficos de barras e de mosaico para avaliar a associação entre as variáveis "country" (país de origem do filme) e "rating" (classificação indicativa do filme: 14, 18 ou L). Tire suas conclusões sobre a existência ou não de uma associação e, em seguida, realize um teste qui-quadrado para comprovar suas convicções.

```
import pandas as pd
from matplotlib import pyplot as plt
from statsmodels.graphics.mosaicplot import mosaic
df = pd.read_csv("netflix_titles_dataset.csv")
# Nova celula
tab = pd.crosstab(index = df["country"], columns = df["rating"])
tab
# Nova celula
tab.plot.bar(edgecolor = "black")
plt.legend(loc = "upper left")
plt.show()
# Nova celula
fig, ax = plt.subplots(figsize = (12,8))
mosaic(df, ["country", "rating"], ax = ax)
ax.set_xticklabels(df["country"].unique().tolist(), rotation=90)
plt.show()
chi2, p, dof, expected = chi2_contingency(tab)
print("Estatistica do teste:", chi2, "--- p-valor:", p)
```





Os gráficos, assim como o teste de hipóteses indicam que existe uma relação entre "country" e "rating".

2. Em um estudo sobre as consequências do uso do cigarro em uma comunidade relacionou os hábitos de fumo de 240 indivíduos à ocorrência de doenças respiratórias. A tabela de frequências é dada abaixo

Frequência do fumo \ Doenças respiratórias	Não	Sim
Não fuma	32	17
Algumas vezes por semana	28	33
Uma vez por dia	15	22
Várias vezes por dia	26	67

Verifique através de um teste qui-quadrado se existe relação estatísticamente significativa entre o fumo e a ocorrência de doenças respiratórias. Apresente a tabela esperada de frequências, a estatística do teste e sua distribuição sob a hipótese nula. Considere a conclusão do teste com o nível de significância de 5%.

A tabela acima incluindo as informações marginais é dada por

Frequência do fumo \ Doenças respiratórias	Não	Sim	**Total**
Não fuma	32	17	49
Algumas vezes por semana	28	33	61
Uma vez por dia	15	22	37
Várias vezes por dia	26	67	93
Total	101	139	240

A tabela de frequências esperada considera que as variáveis indicadoras da frequência de fumo e de doenças respiratórias são independentes, ou seja, que a proporção esperada em uma célula é o produto das frequências marginais de sua coluna e sua linha dividido pela frequência total. Isso resulta na tabela

Frequência do fumo \ Doenças respiratórias	Não	Sim	**Total**
Não fuma	20,62	28.38	49
Algumas vezes por semana	25.67	35.33	61
Uma vez por dia	15.57	21.43	37
Várias vezes por dia	39.14	53.86	93
Total	101	139	240

Temos a estatística do teste dada por

$$\chi^2 = 1 \sum \sum \frac{(O_{ij} - E_{ij})^2}{E_{ij}} = 18,86.$$

Sob a hipótese nula, sabemos que $\chi^2 \sim \chi^2_{(r-1)(c-1)} = \chi^2_{(4-1)\cdot(2-1)} = \chi^2_3$, ou seja, uma distribuição qui-quadrado com 3 graus de liberdade. O quantil 0.95 **dessa distribuição é dado por $\chi^2_{3\ ;\ 0.95} = 7.81$. Assim, como $\chi^2 > 7.81$, rejeitamos a hipótese nula, concluindo que existe associação entre o cigarro e doenças respiratórias.**

3. Sobre os testes de hipótese não paramétricos classifique as seguintes afirmações em verdadeiro (V) e falso (F), justificando caso seja falso.
(**F**) O teste de Mann-Whitney é o equivalente não-paramétrico do teste T pareado.
O teste de Mann-Whitney é o equivalente não-paramétrico do teste T para amostras independentes.
(**V**) O teste qui-quadrado verifica se existe interação entre duas variáveis categóricas.
(**V**) O teste de Wilcoxon é destinado para verificar a diferença entre duas amostras pareadas.
(**F**) Para que a aplicação de um teste não paramétrico seja necessária, é preciso que todos os grupos testados tenham sua normalidade rejeitada.
Basta que apenas um grupo tenha sua normalidade rejeitada para que precisemos aplicar testes não paramétricos.
(**V**) O teste de Kruskal-Wallis avalia a diferença estatística entre mais de dois grupos, quando a normalidade não é válida.
(**V**) Dado que a distribuição da média amostral tende a uma distribuição normal, é razoável a aplicação do teste T, mesmo que a normalidade das amostras seja rejeitada.

Embora a distribuição da média amostral tende a uma distribuição normal, a suposição dos testes é quanto à amostra em si.
(**F**) O teste qui-quadrado é robusto, sendo útil até mesmo quando algumas classes possuem poucas observações.
O teste não é robusto para grupos com baixa frequência. Quando isso ocorre, é recomendada a mesclagem de grupos diferentes ou a aplicação do teste de escores de Fisher.

4. Para comparar dois algoritmos de classificação, foram obtidas suas acurácias (% de classificação correta) em várias bases de dados. Os resultados estão expressos abaixo:

Base de Dados	Algoritmo A	Algoritmo B
Adult	0.763	0.768
Breast	0.599	0.591
Wisconsin	0.954	0.971
Cmc	0.628	0.661
Ionosphere	0.882	0.888
Iris	0.936	0.931
Liver	0.661	0.668
Lung	0.583	0.583
Lymph	0.775	0.838
Mushroom	1.000	1.000
Tumor	0.940	0.962
Rheum	0.619	0.666
Voting	0.972	0.981
Wine	0.957	0.978

Verifique a normalidade das acurácias de ambos os grupos. Com base no resultado, determine o teste de hipótese mais adequado para comparar o desempenho de ambos os algoritmos e o aplique. Quais conclusões podemos obter ao nível de significância de 5%?
Carregando os dados no Python e testando a normalidade de cada grupo

```
x1 = [0.763, 0.599, 0.954, 0.628, 0.882, 0.936, 0.661, 0.583, 0.775,
1.000, 0.940, 0.619, 0.972, 0.957]
x2 = [0.768, 0.591, 0.971, 0.661, 0.888, 0.931, 0.668, 0.583, 0.838,
1.000, 0.962, 0.666, 0.981, 0.978]
print(shapiro(x1))
print(shapiro(x2))
```

rejeitamos a normalidade em ambos os grupos, considerando o nível de significância de 5%. Sendo assim, é necessária a aplicação de testes não-paramétricos. Neste caso, temos que os algoritmos foram aplicados no mesmo conjunto de dados em diferentes cenários, sendo assim, os valores são pareados. Nos resta, portanto, aplicar o teste de Wilcoxon.

```
from scipy.stats import wilcoxon
wilcoxon(x1, x2)
```

Obtemos um p-valor de 0.0108, que nos leva a rejeitar a hipótese nula de que os algoritmos tem mesma acurácia. Ou seja, os algoritmos têm desempenhos diferentes.

5. Com relação a modelos de regressão linear classifique as seguintes afirmações em verdadeiro (V) e falso (F), justificando caso seja falso.
(**V**)Os coeficiente β_j associado à variável X_j representa a variação média de Y ao aumentar X_j em uma unidade.
(**F**)O intercepto, β_0 representa o valor médio da variável resposta.
O intercepto representa o valor médio de Y quando todas as covariáveis são iguais a zero.
(**V**)Se não rejeitamos a hipótese $H_0 : \beta_j = 0$, podemos concluir que a variável X_j não é significativa para explicar Y.
(**F**)A estimação da variância dos erros e_i não requer que eles tenham uma distribuição conhecida.
Não é necessário especificar uma distribuição dos erros para estimar os coeficientes β_j (usamos o método de mínimos quadrados). Para considerar a variância dos erros, é necessário assumir que eles seguem uma distribuição $N(0, \sigma^2)$.
(**F**)É ideal que o erro de regressão observado para os dados de treinamento seja menor que o erro nos dados de teste.
Quando ocorre o *overfitting*, o erro no conjunto de treino é menor que no conjunto de teste. Isso está longe de um resultado ideal.
(**F**)A inclusão de duas covariáveis X_j e X_k perfeitamente relacionadas ($|\text{Cor}[X_j X_k]| = 1$) aumenta a confiança da estimação dos parâmetros β.
A inclusão de covariáveis perfeitamente relacionadas leva à existência de colunas linearmente dependentes na matriz dos dados, X, fazendo com que o determinante de $X^T X$ seja zero, e que a matriz não seja invertível. Sendo assim, é impossível estimar os parâmetros β neste caso.
(**V**)A inclusão de muitas covariáveis no modelo pode levar a problemas de sobreajuste.

6. O conjunto de dados "mtcars" é muito utilizado como um exemplo para modelos de regressão linear múltipla. Estes dados podem ser carregados com o seguinte comando em Python

```
# Em caso de erro, remova o primeiro # da linha seguinte e execute a celula novamente
#!pip install rdatasets
import rdatasets as rd
import pandas as pd
df = rd.data("mtcars")
df.head()
```

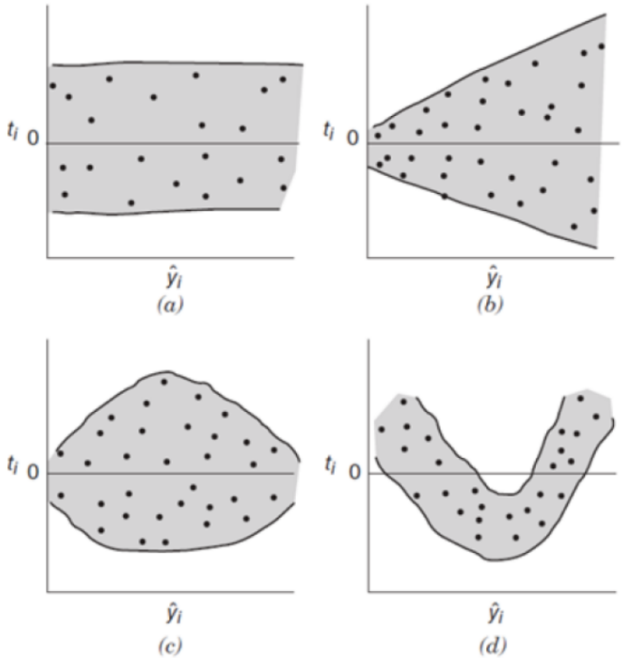
Ajuste uma regressão linear múltipla para a variável mpg (milhas por galão) tendo como variáveis regressoras o deslocamento do motor (disp), os cavalos de potência (hp), a razão do eixo traseiro (drat) e o peso (wt). Quais variáveis são significativas para essa regressão ao nível de significância de 5%? Qual a mudança estimada no número de milhas por galão com o aumento de uma unidade nos cavalos de potência?

```
import rdatasets as rd
import statsmodels.api as sm
df = rd.data("mtcars")
y = df["mpg"]
x = df.loc[:,["disp", "hp", "drat", "wt"]]
x = sm.add_constant(x)
model = sm.OLS(y, x)
print( model.fit().summary() )
```

Temos que, ao nível de significância de 5%, as variáveis significativas são o número

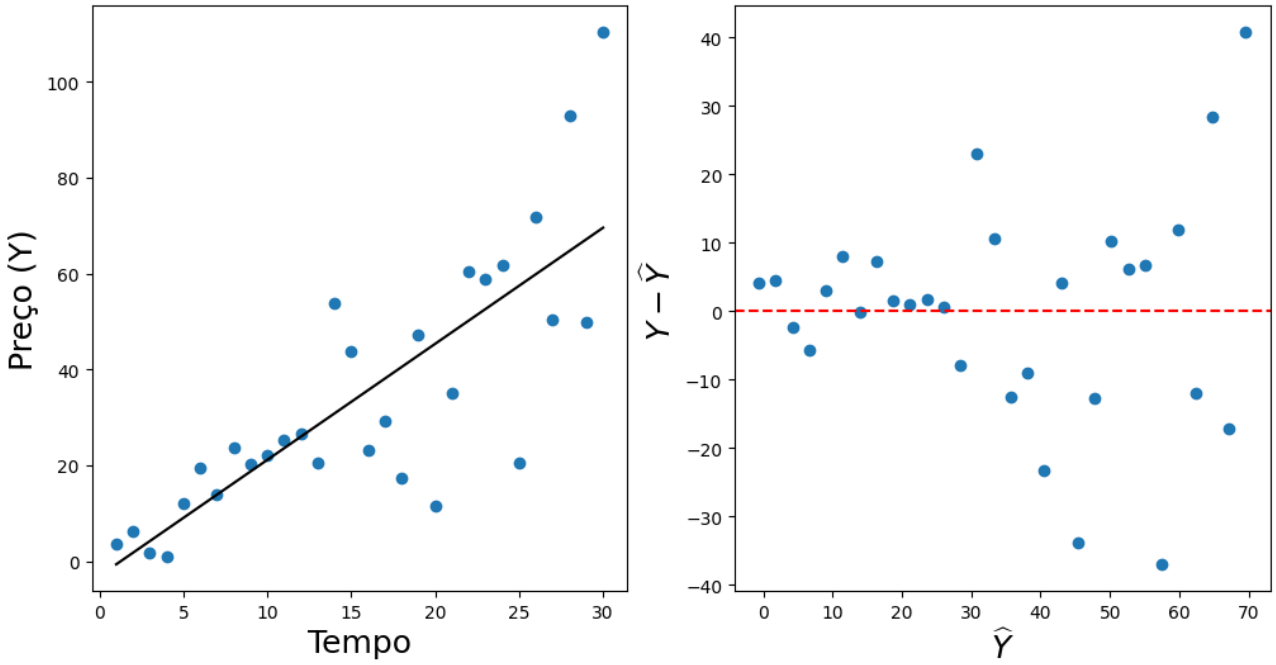
de cavalos de potência, e o peso. Estimamos que, com o aumento de uma unidade nos cavalos de potência, temos uma diminuição de aproximadamente 0.0348 milhas por galão. Ou seja, o aumento da potência do motor, sem alterar as demais variáveis, tende a reduzir a distância percorrida por galão de combustível.

7. Considere a figura abaixo como referência para o exercício. Nela, representamos os resíduos como t_i e os valores preditos como $\widehat{y}_i$



Assinale cada afirmação abaixo como verdadeira (V) ou falsa (F), justificando caso seja falsa.
(**V**) O gráfico (b) indica uma heterocedasticidade dos resíduos.
(**F**) O gráfico (a) indica um mau ajuste do modelo, embora os erros se concentrem em torno do zero.
O gráfico (a) representa a configuração esperada dos erros, caso o modelo esteja bem ajustado.
(**V**) O gráfico (d) indica uma não linearidade, possivelmente causada pela ausência de algum preditor importante no modelo.
(**V**) O gráfico (a) sugere que os resíduos se distribuem em torno de zero.
(**F**) O gráfico (c) indica um bom ajuste do modelo, com erros centralizados em torno da média dos $\widehat{y}_i$.
O gráfico (c) indica que há uma diferença na variância dos erros para diferentes valores preditos, $\widehat{y}_i$. Isso pode indicar um problema de heterocedasticidade e problemas na normalidade dos resíduos.

8. Em um shopping center, foi feito um simples estudo do preço dos itens em uma joalheria ao longo do tempo, em anos, em que o ano zero é considerado como sendo 1995. O resultado de uma regressão linear simples é dado na figura abaixo.



Com base no gráfico de resíduos o modelo está bem ajustado? Justifique em caso positivo e forneça possíveis explicações em caso negativo.

O modelo parece sofrer com um problema de heterocedasticidade dos resíduos, já que percebemos um padrão de "cone" dos erros. Isso indica que a variância dos resíduos parece depender do valor da covariável, X. O tratamento de dados dessa forma pode ser feito com modelos de regressão mais complexos, como os modelos VGLM (*Vector generalized linear models*) e modelos VGAM (*Vector generalized additive models*), por exemplo.

9. Consideremos o conjunto de dados de diabetes do pacote sklearn do Python (`https://scikit-learn.org/stable/datasets/toy_dataset.html#diabetes-dataset`). A tabela de dados pode ser carregada com o comando abaixo

```
from sklearn.datasets import load_diabetes
df = load_diabetes(as_frame = True).frame
df.head()
```

Separe as observações em um conjunto de treinamento e de teste. Proponha diferentes combinações das variáveis (podendo incluir o quadrado das variáveis) para predizer e compare o desempenho dos diferentes modelos no conjunto de teste considerando o erro médio absoluto e a raiz do erro quadrático médio.

10. Dada uma variável resposta Y e p covariáveis $X_1, \ldots, X_p$. Suponha que os dados foram divididos em um conjunto de treinamento (usado para o treinamento do modelo) e um conjunto de teste (usado para a avaliação final dos modelos).

considere o seguinte método de seleção de variáveis:

1. Ajuste p modelos de regressão simples no conjunto de teste, com formas

$$Y = \beta_0 + \beta_1 X_j, \qquad j = 1, \cdots, p$$

2. Compare o desempenho dos p modelos ajustados com base na raiz do erro quadrático médio por validação cruzada no conjunto de treinamento e selecione a variável X_j com o menor erro.

3. Ajuste todos os $p-1$ modelos de regressão da forma

$$Y = \beta_0 + \beta_1 X_j + \beta_2 X_k, \qquad k = 1, 2, \cdots j-1, j+1, \cdots, p$$

   Selecione a variável X_k que resulta no menor erro (validação cruzada).

4. Repita o processo, adicionando variáveis ao modelo até que todos os modelos em um determinado passo tenham um desempenho pior (validação cruzada) do que o modelo atual ou até que todas as covariáveis tenham sido adicionadas ao modelo.

O método acima é usualmente chamado pela comunidade estatística como regressão Stepwise, na qual ajustamos diferentes modelos sucetivamente de forma "gananciosa" (método *greedy*) até encontrar o melhor. Uma forma de aplicar a seleção acima se dá com o uso da função "SequentialFeatureSelector" do pacote sklearn (`https://scikit-learn.org/stable/modules/generated/sklearn.feature_selection.SequentialFeatureSelector.html`). Considerando a mesma base de dados do Exercício 9, faça a seleção de variáveis considerando o método acima e compare com a seleção resultado do modelo de regressão LASSO.