Lista de Exercícios - Quinzena 2
Módulo 2: Métodos estatísticos aplicados
Professora: Cibele Russo
Monitor: Natan Hilário

1. O código abaixo carrega a base de dados dos passageiros do Titanic.

```
df = pd.read_csv("https://raw.githubusercontent.com/" + \
"datasciencedojo/datasets/refs/heads/master/titanic.csv")
df = df.loc[:, ["Survived", "Sex", "Age", "Embarked", "SibSp", "Parch", "Fare", "Pclass"]]
df = df.dropna()

df.columns = ["Sobreviveu", "Sexo", "Idade", "Porto", "IrmaosConjuge", "PaisFilhos",
"Preco", "Classe"]
df.loc[df["Porto"] == "S", "Porto"] = "Southampton"
df.loc[df["Porto"] == "Q", "Porto"] = "Queenstown"
df.loc[df["Porto"] == "C", "Porto"] = "Cherbourg"
df.loc[df["Sexo"] == "male", "Sexo"] = "Masculino"
df.loc[df["Sexo"] == "female", "Sexo"] = "Feminino"
df.head()
```

a) Faça uma análise exploratória de dados, buscando relações interessantes entre as variáveis fornecidas.

b) Ajuste 5 diferentes modelos de regressão logística em um conjunto de treino e compare-os segundo a métrica AUC em um conjunto de teste.

c) construa as curvas ROC para cada um dos modelos do item anterior em um mesmo gráfico.

2. Considerando a base do Titanic do exercício anterior, considere a saída para o modelo de regressão logística abaixo:

Generalized Linear Model Regression Results

Dep. Variable:	Sobreviveu	No. Observations:	569
Model:	GLM	Df Residuals:	567
Model Family:	Binomial	Df Model:	1
Link Function:	Logit	Scale:	1.0000
Method:	IRLS	Log-Likelihood:	-296.74
Date:	Sat, 03 May 2025	Deviance:	593.49
Time:	12:29:20	Pearson chi2:	569.
No. Iterations:	4	Pseudo R-squ. (CS):	0.2639
Covariance Type:	nonrobust		

	coef	std err	z	P>|z|	[0.025	0.975]
Intercept	1.1868	0.167	7.122	0.000	0.860	1.513
Sexo[T.Masculino]	-2.5328	0.211	-12.027	0.000	-2.946	-2.120

a) Obtenha a probabilidade de sobrevivência estimada pelo modelo acima de uma mulher e de um homem sobreviver ao naufrágio do Titanic.

b) Lembrando que a chance é dada por $p/(1-p)$, calcule a razão de chances entre as probabilidades do item acima e compare com o exponencial do coeficiente do sexo masculino ($\exp\{-2.5328\}$). O que podemos concluir?

3. O código abaixo carrega uma base de dados de dados pública referente a 303 pacientes e remove as 6 observações que contém informações faltantes. O propósito é prever quais deles sofre de doença do coração ou não.

```
df = pd.read_csv("https://raw.githubusercontent.com/" + \
"JWarmenhoven/ISLR-python/refs/heads/master/Notebooks/Data/Heart.csv").iloc[:,1:]
df = df.dropna()
print("Dimensao dos dados: {}".format(df.shape))
df.head()
```

Com base nos dados carregados acima,

a) Faça uma lista das colunas do conjunto de dados, descrevendo o que cada uma significa. (**Dica:** `https://www.kaggle.com/datasets/ritwikb3/heart-disease-cleveland`)

b) Ajuste um modelo de regressão logística considerando as variáveis "Idade" (Age), "Sexo" (Sex) e "Dor no peito" (ChestPain). Interprete os resultados do ajuste.

c) Construa 5 diferentes combinações de variáveis preditoras e compare os modelos correspondentes em uma base de dados de teste usando como critério a área abaixo da curva ROC.

d) Aplique o algoritmo Stepwise até a estabilização do modelo em uma combinação de variáveis que não permita mais a diminuição da métrica do AIC.

4. Ao estudar a taxa de inadimplência, um banco virtual aplica dois modelos de classificação binária para um conjunto de teste de 150 clientes. Considerando que "0" representa clientes adimplentes e "1", clientes inadimplentes, as matrizes de confusão obtidas foram

		Modelo 1		Modelo 2	
		Classe real		Classe real	
		0	1	0	1
Classe predita	0	128	22	99	5
	1	0	0	29	17

a) Obtenha as métricas de acurácia, sensibilidade (recall) e de especificidade para ambos os modelos. Segundo a acurácia, qual modelo deveria ser selecionado?

b) Um analista do banco optou por utilizar a acurácia para selecionar o modelo da produção. Meses depois, percebeu-se que o modelo se saiu extremamente mal no ambiente de produção do banco. Argumente as possíveis razões deste problema.

5. Considerando os dados de diabetes do pacote sklearn do Python, carregado com

```
from sklearn.datasets import load_diabetes
df = load_diabetes(as_frame = True).frame
df.head()
```

ajuste uma regressão linear múltipla Bayesiana considerando as variáveis ´´age", ´´bmi" e ´´bp". Construa os gráficos de traço para cada um dos coeficientes de regressão das amostras MCMC da distribuição a posteriori dos parâmetros.

6. Com base nos dados do Titanic, utilize o PyMC para ajustar os modelos logísticos Bayesianos referentes a cada um modelo considerado no Exercício 1, item b. No contexto de regressão

Bayesiano, dizemos que uma variável não é significativa caso o intervalo de credibilidade associado ao seu coeficiente de regressão contém o zero. Determine se a conclusão de quais variáveis foram significativas coincide entre os modelos frequentista e Bayesiano.

7. Com relação à inferência Bayesiana, classifique as seguintes afirmações em verdadeiro (V) e falso (F), justificando caso seja falso

( ) O estimador de máxima verossimilhança pode ser interpretado como a moda a posteriori quando utilizamos uma priori "flat" (uniforme).

( ) A inferência Bayesiana tem o interesse em utilizar as informações dos parâmetros a priori.

( ) Nos métodos MCMC é usual retirarmos as amostras iniciais para a obtenção de melhores resultados.

( ) A moda a posteriori representa o ponto de máximo da densidade a posteriori.

( ) Se a distribuição a posteriori não pode ser obtida de forma fechada, devemos adotar métodos frequentistas para a estimação dos parâmetros.

8. Suponha que $T_1, \ldots, T_n$ representa uma amostra independente e identicamente distribuída (iid) da distribuição Exponencial, com parâmetro λ, ou seja, com densidade

$$f(t|\lambda) = \lambda e^{-\lambda t}.$$

a) Obtenha o estimador de máxima verossimilhança para o parâmetro λ.

b) Supondo a distribuição a priori constante e igual a 1 para λ, obtenha o núcleo da sua distribuição a posteriori.

c) Dizemos que uma variável aleatória, Z, tem distribuição Gama, com parâmetros α e β, quando seu núcleo é da seguinte forma

$$f(z|\alpha, \beta) \propto z^{\alpha-1} e^{-\beta z}.$$

Temos que a média da distribuição Gama é expressa por α/β. Obtenha a média a posteriori para o parâmetro λ, no item (b).

9. A descrição do Wikipedia para o teste A/B é dada a seguir:

"Teste A/B é um método de teste de design através do qual comparam-se elementos aleatórios com duas variantes, A e B, em que estes são o controle e o tratamento de uma experiência controlada, com o objetivo de melhorar a percentagem de aprovação. Estas experiências são muito utilizadas em desenvolvimento web e de marketing, e até mesmo em formas tradicionais de publicidade. O teste A/B também se designa por experiência aleatória controlada, experiência online controlada e teste de divisão. Em web design, o teste A/B é utilizado para identificar alterações nas páginas web que podem provocar mudanças positivas ou negativas no interesse dos utilizadores. Como o nome já diz, duas versões são comparadas, as quais são idênticas exceto por uma variante que pode impactar o comportamento do utilizador. A versão A pode ser a versão utilizada atualmente (controle), enquanto a versão B é a modificada (tratamento)."

Suponha que um teste A/B será realizado para comparar duas versões diferentes de páginas web (aa e bb). Contou-se o número de visitantes em cada página e se clicaram ou não em algum dos links desejados, com os seguintes resultados:

	Não clicou	**Clicou**
aa	4514 (90.06%)	498 (9.94%)
bb	4473 (88.05%)	607 (11.95%)

Supondo que a proporção de cliques de cada grupo a priori siga uma distribuição uniforme no intervalo $(0, 1)$, obtenha a distribuição a posteriori da proporção de cada grupo. Construa a curva da densidade a posteriori para a proporção de ambos os grupos em um mesmo gráfico.

10. Utilizando os dados do exercício 3, aplique os mesmos modelos utilizados nos itens (b) e (c), porém considerando a biblioteca PyMC para o ajuste do MLG Bayesiano. As variáveis significativas coincidem? Verifique a convergência das cadeias e interprete os resultados.