Lista de Exercícios com GABARITO - Quinzena 2
Módulo 2: Métodos estatísticos aplicados
Professora: Cibele Russo
Monitor: Natan Hilário

1. O código abaixo carrega a base de dados dos passageiros do Titanic.

```
df = pd.read_csv("https://raw.githubusercontent.com/" + \
"datasciencedojo/datasets/refs/heads/master/titanic.csv")
df = df.loc[:, ["Survived", "Sex", "Age", "Embarked", "SibSp", "Parch", "Fare", "Pclass"]]
df = df.dropna()

df.columns = ["Sobreviveu", "Sexo", "Idade", "Porto", "IrmaosConjuge", "PaisFilhos",
"Preco", "Classe"]
df.loc[df["Porto"] == "S", "Porto"] = "Southampton"
df.loc[df["Porto"] == "Q", "Porto"] = "Queenstown"
df.loc[df["Porto"] == "C", "Porto"] = "Cherbourg"
df.loc[df["Sexo"] == "male", "Sexo"] = "Masculino"
df.loc[df["Sexo"] == "female", "Sexo"] = "Feminino"
df.head()
```

a) Faça uma análise exploratória de dados, buscando relações interessantes entre as variáveis fornecidas.

b) Ajuste 5 diferentes modelos de regressão logística em um conjunto de treino e compare-os segundo a métrica AUC em um conjunto de teste.

c) construa as curvas ROC para cada um dos modelos do item anterior em um mesmo gráfico.

2. Considerando a base do Titanic do exercício anterior, considere a saída para o modelo de regressão logística abaixo:

Generalized Linear Model Regression Results

Dep. Variable:	Sobreviveu	No. Observations:	569
Model:	GLM	Df Residuals:	567
Model Family:	Binomial	Df Model:	1
Link Function:	Logit	Scale:	1.0000
Method:	IRLS	Log-Likelihood:	-296.74
Date:	Sat, 03 May 2025	Deviance:	593.49
Time:	12:29:20	Pearson chi2:	569.
No. Iterations:	4	Pseudo R-squ. (CS):	0.2639
Covariance Type:	nonrobust		

	coef	std err	z	P>|z|	[0.025	0.975]
Intercept	1.1868	0.167	7.122	0.000	0.860	1.513
Sexo[T.Masculino]	-2.5328	0.211	-12.027	0.000	-2.946	-2.120

a) Obtenha a probabilidade de sobrevivência estimada pelo modelo acima de uma mulher e de um homem sobreviver ao naufrágio do Titanic.

b) Lembrando que a chance é dada por $p/(1-p)$, calcule a razão de chances entre as probabilidades do item acima e compare com o exponencial do coeficiente do sexo masculino ($\exp\{-2.5328\}$). O que podemos concluir?

a) As probabilidades de ambos os sexos são dadas por

$$P(Y = 1|\text{Feminino}) = \text{logito}(1.1868) = \frac{1}{1 + e^{-1.1868}} = 0.7662$$
$$P(Y = 1|\text{Masculino}) = \text{logito}(1.1868 - 2.5328) = \text{logito}(-1.346) = \frac{1}{1 + e^{1.346}} = 0.2065$$

b) Escrevemos ambas chances como

$$C_{\text{feminino}} = \frac{0.7662}{1 - 0.7662} = 3.2772$$
$$C_{\text{masculino}} = \frac{0.2065}{1 - 0.2065} = 0.2602$$

Agora, a razão de chances entre os sexos será dada por

$$R = \frac{C_{\text{feminino}}}{C_{\text{masculino}}} = 12.5949,$$

Ou seja, uma mulher no Titanic tinha uma chance aproximadamente 12.6 vezes maior de sobrevivência que um homem. Calculando $e^{-2.5328}$ e $1/e^{-2.5328}$ fica evidente que $e^{\beta_{\text{sexo}}}$ representa justamente essa mesma razão de chances. (O resultado não é exatamente o mesmo caso consideremos os valores arredondados. Considerando todas as casas decimais dos resultados do pacote a razão de chances acima resultaria exatamente em $1/e^{\beta_{\text{sexo}}}$)

3. O código abaixo carrega uma base de dados de dados pública referente a 303 pacientes e remove as 6 observações que contém informações faltantes. O propósito é prever quais deles sofre de doença do coração ou não.

Com base nos dados carregados acima,

a) Faça uma lista das colunas do conjunto de dados, descrevendo o que cada uma significa. (**Dica:** `https://www.kaggle.com/datasets/ritwikb3/heart-disease-cleveland`)

b) Ajuste um modelo de regressão logística considerando as variáveis "Idade" (Age), "Sexo" (Sex) e "Dor no peito" (ChestPain). Interprete os resultados do ajuste.

c) Construa 5 diferentes combinações de variáveis preditoras e compare os modelos correspondentes em uma base de dados de teste usando como critério a área abaixo da curva ROC.

d) Aplique o algoritmo Stepwise até a estabilização do modelo em uma combinação de variáveis que não permita mais a diminuição da métrica do AIC.

Uma referência para o ajuste do modelo. O código mostra que podemos escolher qual categoria da variável ChestPain será incorporada no intercepto, ou seja, removida das variáveis indicadoras. No caso, escolhemos a categoria dos assintomáticos neste caso.

```
from sklearn.model_selection import train_test_split
import statsmodels.api as sm
from statsmodels.formula.api import glm

df = df.loc[:, ["Age", "Sex", "ChestPain", "Chol", "AHD"]]
df.loc[df["AHD"] == "Yes", "AHD"] = 1
```

```
df.loc[df["AHD"] == "No", "AHD"] = 0
df["AHD"] = df["AHD"].astype("uint8")

df["Sex"] = df["Sex"].astype("str")
df.loc[df["Sex"] == "1", "Sex"] = "Masculino"
df.loc[df["Sex"] == "0", "Sex"] = "Feminino"

df.loc[df["ChestPain"] == "typical", "ChestPain"] = "Angina tipica"
df.loc[df["ChestPain"] == "nontypical", "ChestPain"] = "Angina atipica"
df.loc[df["ChestPain"] == "nonanginal", "ChestPain"] = "Nao anginosa"
df.loc[df["ChestPain"] == "asymptomatic", "ChestPain"] = "Assintomatico"

df_train, df_test = train_test_split(df, train_size = 0.8, random_state = 1)

# Lembre-se de apagar '~' e reescreve-lo,
# assim como as aspas unicas em 'Feminino' e 'Assintomatico'.
# A formataçao do PDF substitui esses caracteres
fit = glm("AHD ~Age + C(Sex, Treatment(reference='Feminino')) + " + \
"C(ChestPain, Treatment(reference='Assintomatico'))", data = df_train,
family = sm.families.Binomial()).fit()
print( fit.summary().tables[0] )

coef_table = fit.summary2().tables[1]
coef_table.index = ["Intercepto",
                    "Sexo masculino",
                    "DorPeito -> Angina atipica",
                    "DorPeito -> Angina tipica",
                    "DorPeito -> Nao anginosa",
                    "Idade"]
print( coef_table.to_string() )
```

4. Ao estudar a taxa de inadimplência, um banco virtual aplica dois modelos de classificação binária para um conjunto de teste de 150 clientes. Considerando que "0" representa clientes adimplentes e "1", clientes inadimplentes, as matrizes de confusão obtidas foram

		Modelo 1		Modelo 2	
		Classe real		Classe real	
		0	1	0	1
Classe predita	0	128	22	99	5
	1	0	0	29	17

a) Obtenha as métricas de acurácia, sensibilidade (recall) e de especificidade para ambos os modelos. Segundo a acurácia, qual modelo deveria ser selecionado?

b) Um analista do banco optou por utilizar a acurácia para selecionar o modelo da produção. Meses depois, percebeu-se que o modelo se saiu extremamente mal no ambiente de produção do banco. Argumente as possíveis razões deste problema.

Para o Modelo 1, temos

Acurácia: 85.33%

Sensibilidade: 0%

Especificidade: 100%

Para o Modelo 2, temos

Acurácia: 69.33%
Sensibilidade: 77.27%
Especificidade: 77.34%

Utilizando a acurácia como base, devemos selecionar como o melhor o Modelo 1.

b) Analisando as matrizes de confusão, note que o Modelo 1, embora tenha uma acurácia maior, não foi capaz de detectar nenhum dos clientes verdadeiramente inadimplentes, que é justamente a razão para o desenvolvimento dos modelos. Por sua vez, dos únicos 22 clientes inadimplentes do conjunto de dados, o Modelo 2 foi capaz de identificar corretamente 17 pessoas. Veja que o Modelo 1 "aprendeu" que se prever todas as *labels* como zero, estará obtendo altas acurácias devido ao baixíssimo número de observações da classe positiva. Por sua vez, o modelo 2, embora apresente uma menor acurácia, de fato é capaz de diferenciar as classes, tornando-o muito mais robusto para a aplicação na produção, neste caso.

5. Considerando os dados de diabetes do pacote sklearn do Python, carregado com

```
from sklearn.datasets import load_diabetes
df = load_diabetes(as_frame = True).frame
df.head()
```

ajuste uma regressão linear múltipla Bayesiana considerando as variáveis "age", "bmi" e "bp" através do pacote PyMC. Construa os gráficos de traço para cada um dos coeficientes de regressão das amostras MCMC da distribuição a posteriori dos parâmetros.

Um código de base:

```
import warnings
import pandas as pd
import numpy as np
import seaborn as sns
import arviz as az
import matplotlib.pyplot as plt
import numpy as np
import pymc as pm

rng = np.random.default_rng(42)
chains = 5
with pm.Model() as mdl_Poisson:
    # Define as prioris como distribuiçoes normais nao informativas
    b0 = pm.Normal("b0", mu=0, sigma=100)
    b_age = pm.Normal("b_age", mu=0, sigma=100)
    b_bmi = pm.Normal("b_bmi", mu=0, sigma=100)
    b_bp = pm.Normal("b_bp", mu=0, sigma=100)
    # Para definir sigma2, usualmente utilizamos a
    # Gamma Inversa com parametros proximos de zero
    # como uma priori pouco informativa
    sigma2 = pm.InverseGamma("sigma2", 0.001, 0.001)

    # Define a componente linear do modelo
    eta = (
```

```
        b0
        + b_age * df["age"]
        + b_bmi * df["bmi"]
        + b_bp * df["bp"]
    )

    obs = pm.Normal("obs", mu = eta, tau = 1/sigma2, observed = df["target"])

    idata = pm.sample(2000, tune = 1500, chains = chains, return_inferencedata=True, random_seed

parameters = ["b0", "b_age", "b_bmi", "b_bp", "sigma2"]
chains_summary = pd.DataFrame()

chains_sample = {}
for par in parameters:
    sampled_chains = idata.posterior[par].values.T
    chains_par = pd.DataFrame( sampled_chains )
    chains_size = chains_par.shape[0]
    chains_par = chains_par.melt()
    chains_par["index"] = np.arange(chains_size).tolist() * chains
    chains_par["variable"] = chains_par["variable"].astype("str")
    chains_par.columns = ["chain", "value", "index"]
    chains_par["const"] = 1
    chains_sample[par] = chains_par

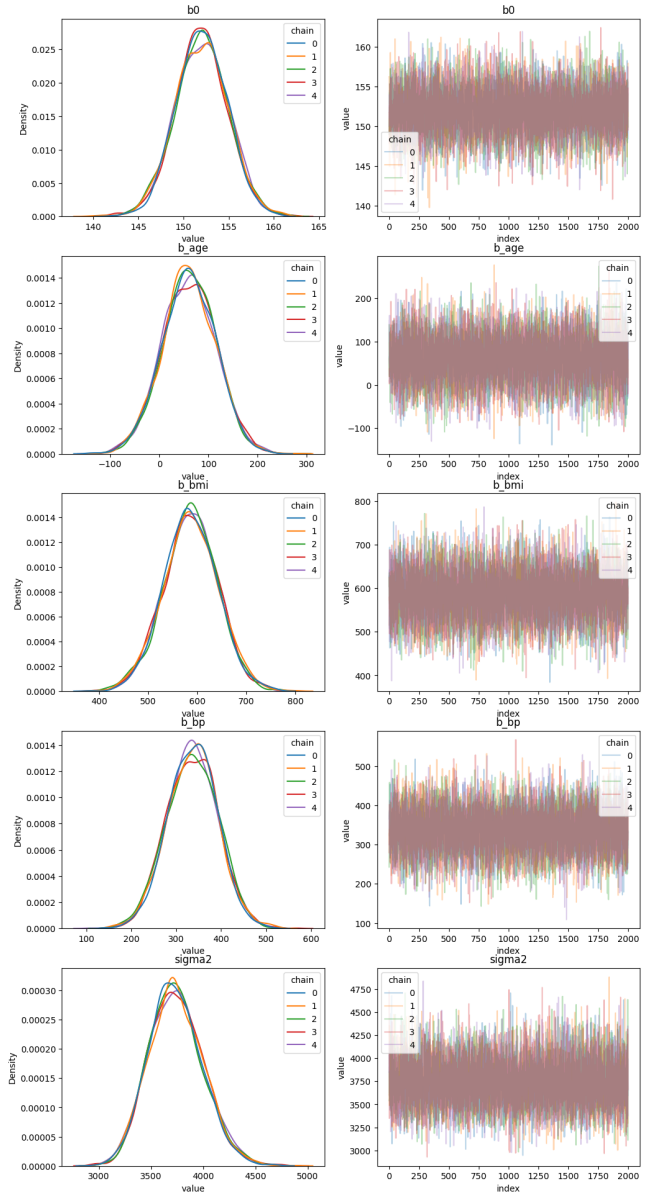
    chains_par_summary = chains_par.groupby("const").agg(
        mean = ("value", "mean"),
        median=('value', 'median'),
        sd=('value', 'std'),
        q025=('value', lambda x: x.quantile(0.025)),
        q975=('value', lambda x: x.quantile(0.975)),
        n=('value', 'count')
    ).reset_index(drop = True)
    chains_par_summary.insert(0, "Parameter", par)

    chains_summary = pd.concat([chains_summary, chains_par_summary])

    def plot_trace(chains_par, ax1, ax2, title = ""):
    sns.kdeplot(x = "value", hue = "chain", data = chains_par, ax = ax1)
    sns.lineplot(x = "index", y = "value", hue = "chain", alpha = 0.3, data = chains_par, ax = a
    ax1.set_title(title)
    ax2.set_title(title)

fig, ax = plt.subplots(nrows = len(parameters), ncols = 2, figsize = (12, 24))

for i, par in enumerate(parameters):
    plot_trace(chains_sample[par], ax[i,0], ax[i,1], title = par)
```



6. Com base nos dados do Titanic, utilize o PyMC para ajustar os modelos logísticos Bayesianos referentes a cada um modelo considerado no Exercício 1, item b. No contexto de regressão Bayesiano, dizemos que uma variável não é significativa caso o intervalo de credibilidade associado ao seu coeficiente de regressão contém o zero. Determine se a conclusão de quais variáveis foram significativas coincide entre os modelos frequentista e Bayesiano.

7. Com relação à inferência Bayesiana, classifique as seguintes afirmações em verdadeiro (V) e falso (F), justificando caso seja falso

(**V**) O estimador de máxima verossimilhança pode ser interpretado como a moda a posteriori quando utilizamos uma priori "flat" (uniforme).

(**F**) A inferência Bayesiana tem o interesse em utilizar as informações dos parâmetros a priori. **O interesse da inferência Bayesiana consiste na informação a posteriori dos parâmetros, que é uma ponderação entre a informação a priori e o resultado dos dados.**

(**V**) Nos métodos MCMC é usual retirarmos as amostras iniciais para a obtenção de melhores resultados.

(**V**) A moda a posteriori representa o ponto de máximo da densidade a posteriori.

(**F**) Se a distribuição a posteriori não pode ser obtida de forma fechada, devemos adotar métodos frequentistas para a estimação dos parâmetros.

A maior motivação do uso dos métodos MCMC em inferência Bayesiana se dá quando a posteriori não possui forma fechada. Sendo assim, é totalmente possível contornar esses problemas, não sendo necessária a aplicação de métodos frequentistas. De fato, a maior parte dos modelos Bayesianos aplicados na prática não tem posterioris conhecidas.

8. Suponha que $T_1, \ldots, T_n$ representa uma amostra independente e identicamente distribuída (iid) da distribuição Exponencial, com parâmetro λ, ou seja, com densidade

$$f(t|\lambda) = \lambda e^{-\lambda t}.$$

a) Obtenha o estimador de máxima verossimilhança para o parâmetro λ.

b) Supondo a distribuição a priori constante e igual a 1 para λ, obtenha o núcleo da sua distribuição a posteriori.

c) Dizemos que uma variável aleatória, Z, tem distribuição Gama, com parâmetros α e β, quando seu núcleo é da seguinte forma

$$f(z|\alpha, \beta) \propto z^{\alpha-1} e^{-\beta z}.$$

Temos que a média da distribuição Gama é expressa por α/β. Obtenha a média a posteriori para o parâmetro λ, no item (b).

a) Escrevemos a verossimilhança da amostra e seu respectivo logaritmo como

$$L(\lambda|\boldsymbol{t}) = \prod_{i=1}^{n} f(t_i|\lambda) = \prod_{i=1}^{n} \lambda e^{-\lambda t_i} = \lambda^n e^{-\lambda \sum_{i=1}^{n} t_i},$$

$$\ell(\lambda|\boldsymbol{t}) = \log L(\lambda|\boldsymbol{t}) = n \log \lambda - \lambda \sum_{i=1}^{n} t_i.$$

Para obtermos o máximo a verossimilhança, derivamos $\ell(\lambda|\boldsymbol{t})$ com relação a λ e igualamos a zero. Temos que

$$\left.\frac{\partial \ell(\lambda|\boldsymbol{t})}{\partial \lambda}\right|_{\lambda=\widehat{\lambda}} = \frac{n}{\widehat{\lambda}} - \sum_{i=1}^{n} t_i = 0 \Rightarrow \widehat{\lambda} = \frac{n}{\sum_{i=1}^{n} t_i} = \frac{1}{\bar{t}}.$$

Assim, o estimador de máxima verossimilhança para λ é o inverso da média amostral.

b) Considerando a distribuição a priori $\pi(\lambda) \propto 1$ e sabendo que a densidade conjunta da amostra é

$$f(\boldsymbol{t}|\lambda) = \prod_{i=1}^{n} \lambda e^{-\lambda t_i} = \lambda^n e^{-\lambda \sum_{i=1}^{n} t_i},$$

obtemos que o núcleo da distribuição a posteriori é dado por

$$\pi(\lambda|\boldsymbol{t}) \propto \pi(\lambda) f(\boldsymbol{t}|\lambda) \propto \lambda^n e^{-\lambda \sum_{i=1}^{n} t_i}.$$

c) A partir do núcleo obtido no item (b), podemos concluir que a distribuição a posteriori do parâmetro λ é uma distribuição Gama com parâmetros $\alpha = n + 1$ e $\beta = \sum_{i=1}^{n} t_i$. Sendo assim, a média a posteriori do parâmetro λ é dada por

$$E[\lambda|\boldsymbol{t}] = \frac{\alpha}{\beta} = \frac{n+1}{\sum_{i=1}^{n} t_i}.$$

9. A descrição do Wikipedia para o teste A/B é dada a seguir:

"Teste A/B é um método de teste de design através do qual comparam-se elementos aleatórios com duas variantes, A e B, em que estes são o controle e o tratamento de uma experiência controlada, com o objetivo de melhorar a percentagem de aprovação. Estas experiências são muito utilizadas em desenvolvimento web e de marketing, e até mesmo em formas tradicionais de publicidade. O teste A/B também se designa por experiência aleatória controlada, experiência online controlada e teste de divisão. Em web design, o teste A/B é utilizado para identificar alterações nas páginas web que podem provocar mudanças positivas ou negativas no interesse dos utilizadores. Como o nome já diz, duas versões são comparadas, as quais são idênticas exceto por uma variante que pode impactar o comportamento do utilizador. A versão A pode ser a versão utilizada atualmente (controle), enquanto a versão B é a modificada (tratamento)."

Suponha que um teste A/B será realizado para comparar duas versões diferentes de páginas web (aa e bb). Contou-se o número de visitantes em cada página e se clicaram ou não em algum dos links desejados, com os seguintes resultados:

	Não clicou	**Clicou**
aa	4514 (90.06%)	498 (9.94%)
bb	4473 (88.05%)	607 (11.95%)

Supondo que a proporção de cliques de cada grupo a priori siga uma distribuição uniforme no intervalo $(0, 1)$, obtenha a distribuição a posteriori da proporção de cada grupo. Construa a curva da densidade a posteriori para a proporção de ambos os grupos em um mesmo gráfico.

Para o grupo "aa" temos que a amostra X_{aa} tem distribuição Binomial(n = 5012, p_{aa}). Por sua vez, a amostra X_{bb} segue uma Binomial(n = 5080, p_{bb}). Ademais, as prioris dadas são $\pi(p_{aa}) \propto \pi(p_{bb}) \propto 1$. Assim, temos os seguintes núcleos a posteriori

$$\pi(p_{aa}|x_{aa}) \propto \pi(p_{aa}) f(x_{aa}|p_{aa}) \propto 1 \cdot p^{x_{aa}}(1-p)^{5012-x_{aa}} = p^{x_{aa}+1-1}(1-p)^{5013-x_{aa}-1},$$
$$\pi(p_{bb}|x_{bb}) \propto \pi(p_{bb}) f(x_{bb}|p_{bb}) \propto 1 \cdot p^{x_{bb}}(1-p)^{5080-x_{bb}} = p^{x_{bb}+1-1}(1-p)^{5081-x_{bb}-1}.$$

Observando os núcleos e substituindo $x_{aa} = 498$ e $x_{bb} = 607$, obtemos que o grupo "aa" tem proporção a posteriori dada por uma

$$\text{Beta}(\alpha = x_{aa} + 1, \beta = 5013 - x_{aa}) = \text{Beta}(\alpha = 499, \beta = 4515),$$

enquanto que o grupo "bb" tem uma posteriori dada por

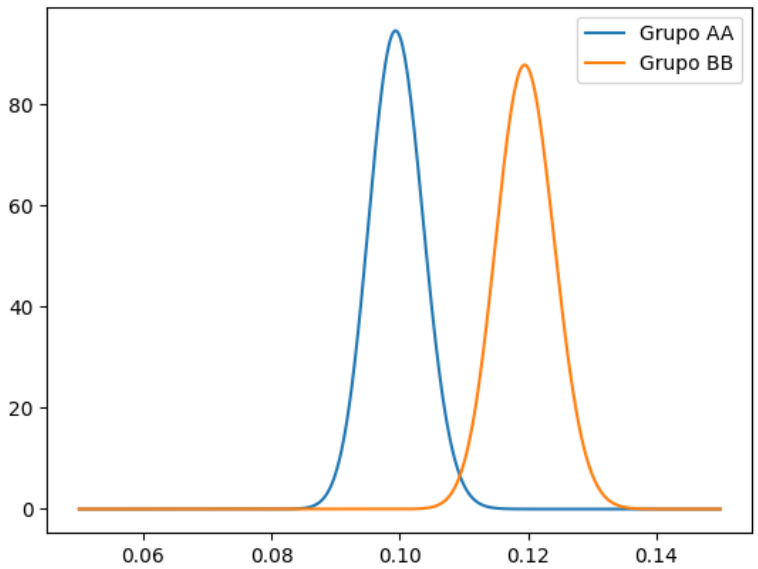
$$\text{Beta}(\alpha = x_{bb} + 1, \beta = 5081 - x_{bb}) = \text{Beta}(\alpha = 608, \beta = 4474).$$

```
n = 1000
x = np.linspace(0.05, 0.15, n)

densidade_grupo_AA = beta.pdf(x, a = 499, b = 4515)
densidade_grupo_BB = beta.pdf(x, a = 608, b = 4474)

plt.plot(x, densidade_grupo_AA, label = "Grupo AA")
plt.plot(x, densidade_grupo_BB, label = "Grupo BB")
plt.legend()
plt.show()
```

A partir do gráfico das densidades, é evidente que a distribuição a posteriori para a proporção de cliques no design "bb" é notadamente superior à proporção de cliques no modelo "aa", indicando uma preferência para o modelo "bb".



10. Utilizando os dados do exercício 3, aplique os mesmos modelos utilizados nos itens (b) e (c), porém considerando a biblioteca PyMC para o ajuste do MLG Bayesiano. As variáveis significativas coincidem? Verifique a convergência das cadeias e interprete os resultados.