Lista de Fixação - CDPO

Iaago Ariel Schwoelk Lobo

15 de maio de 2025

Questão 1

Escreva **V** para **Verdadeiro** e **F** para **Falso** para as afirmativas abaixo acerca de metaheurísticas.

(**F**) Metaheurísticas podem ser aplicadas somente para problemas MILP.

(**V**) Metaheurísticas tem menor custo computacional comparadas aos métodos exatos, mas podem não encontrar a solução ótima.

(**F**) Uma metaheurística pode **não** encontrar uma solução ótima muitas vezes, mas ela reconhece um otimizador se encontrá-lo.

(**V**) As metaheurísticas são bastante úteis para problemas difíceis como o TSP.

(**F**) Uma metaheurística devem utilizar subrotinas complexas como a solução de um problema relaxado para encontrar uma solução boa.

Questão 2

Na busca Tabu, uma das subrotinas mais importantes é a geração de uma vizinhança ao redor de uma solução $\boldsymbol{x}$, geralmente denotada por $\mathcal{N}(\boldsymbol{x})$.

Suponha que num problema de otimização binária a solução inicial é dada por um vetor

$$\boldsymbol{x}_0 = (1, 0, 0, 0, 1, 1, 0, 1).$$

a) Descreva 2 formas distintas de gerar uma vizinhança a partir da solução inicial $\boldsymbol{x}_0$.

b) Escreva 2 soluções que são vizinhas de $\boldsymbol{x}_0$ e duas que não são a partir das vizinhanças que você criou.

Gabarito:

a) *Bit flipping*. São soluções vizinhas de $\boldsymbol{x}_0$ todas as soluções que tiverem apenas 1 coordenada distinta de $\boldsymbol{x}_0$. Assim, a vizinhança $\mathcal{N}_A(\boldsymbol{x}_0)$ será

$$\mathcal{N}_A(\boldsymbol{x}_0) = \mathcal{N}_A\left(\begin{pmatrix}1\\0\\0\\0\\1\\1\\0\\1\end{pmatrix}\right) = \left\{\begin{pmatrix}0\\0\\0\\0\\1\\1\\0\\1\end{pmatrix}, \begin{pmatrix}1\\1\\0\\0\\1\\1\\0\\1\end{pmatrix}, \begin{pmatrix}1\\0\\1\\0\\1\\1\\0\\1\end{pmatrix}, \begin{pmatrix}1\\0\\0\\1\\1\\1\\0\\1\end{pmatrix}, \begin{pmatrix}1\\0\\0\\0\\0\\1\\0\\1\end{pmatrix}, \begin{pmatrix}1\\0\\0\\0\\1\\0\\0\\1\end{pmatrix}, \begin{pmatrix}1\\0\\0\\0\\1\\1\\1\\1\end{pmatrix}, \begin{pmatrix}1\\0\\0\\0\\1\\1\\0\\0\end{pmatrix}\right\}$$

.

Circular shift. Outra forma de gerar uma vizinhança é por meio da rotação dos bits de uma solução. Seja a substituição $x_i \leftarrow x_{i+1}$ para $i \in \{1, \cdots, 7\}$ e $x_8 = x_1$. Obtemos uma rotação dos valores dos elementos de $\boldsymbol{x}_0$. Desse modo, para essa nova vizinhança $\mathcal{N}_B(\boldsymbol{x}_0)$ temos

$$\mathcal{N}_B(\boldsymbol{x}_0) = \mathcal{N}_B\left(\begin{pmatrix}1\\0\\0\\0\\1\\1\\0\\1\end{pmatrix}\right) = \left\{\begin{pmatrix}1\\1\\0\\0\\0\\1\\1\\0\end{pmatrix}, \begin{pmatrix}0\\1\\1\\0\\0\\0\\1\\1\end{pmatrix}, \begin{pmatrix}1\\0\\1\\1\\0\\0\\0\\1\end{pmatrix}, \begin{pmatrix}1\\1\\0\\1\\1\\0\\0\\0\end{pmatrix}, \begin{pmatrix}0\\1\\1\\0\\1\\1\\0\\0\end{pmatrix}, \begin{pmatrix}0\\0\\1\\1\\0\\1\\1\\0\end{pmatrix}, \begin{pmatrix}0\\0\\0\\1\\1\\0\\1\\1\end{pmatrix}\right\}$$

.

b) Basta escolher 2 exemplares das vizinhanças $\mathcal{N}_A$ e $\mathcal{N}_B$ criadas no item a.

2 Soluções que não pertencem a nenhuma das vizinhanças são $\mathbf{1} = (1, 1, 1, 1, 1, 1, 1, 1)$ e $\mathbf{0} = (0, 0, 0, 0, 0, 0, 0, 0)$.

Questão 3

Observe as técnicas de otimização abaixo.

- Algoritmo Simplex.
- Algoritmo Nesterov.
- Busca Tabu.
- Branch and Bound.
- Algoritmo Genético.
- Algoritmo Guloso (ou Ambicioso).
- Simmulated Annealing (Recozimento Simulado).

a) Dos itens acima identifique quais são metaheurísticas.

b) Quais das técnicas acima podem ser utilizadas para resolver um problema de otimização não linear inteira mista (**MINLP**)?

Gabarito:
a) São metaheurísticas a Busca Tabu, Algoritmo Guloso, Algoritmo Genético e Recozimento Simulado.
b) Podem ser empregadas as técnicas de Busca Tabu, *Branch and Bound*, Algoritmo Genético, Algoritmo Guloso, *Simmulated Annealing*. **Isso não quer dizer que qualquer um deles deve ser usado**, no entanto. É preciso conhecer o problema e escolher o método mais apropriado.

Questão 4

Considere que estamos utilizando o método *Branch and Bound* para resolver um problema linear inteiro misto (**MILP**) **de minimização** e que $\mathcal{P}^c$, $\mathcal{P}_r^c$ são o problema corrente e sua relaxaçao, respectivamente, com soluções respectivas $\boldsymbol{x}^c$ e $\boldsymbol{x}_r^c$. Analise as afirmativas a seguir e assinale **V** para **Verdadeiro** e **F** para **Falso**.

(**V**) Se $\mathcal{P}_r^c$ é infactível então $\mathcal{P}^c$ é infactível.

(**F**) Se $f(\boldsymbol{x}_r^c) \geq f(\boldsymbol{x})$ para toda solução viável $\boldsymbol{x}$ do problema, então $\boldsymbol{x}_r^c$ é a solução ótima do problema.

(**F**) Se $\boldsymbol{x}_r^c$ é melhor que a solução incumbente $\boldsymbol{x}^I$, isto é, $f(\boldsymbol{x}_r^c) < f(\boldsymbol{x}^I)$ então subtituimos $\boldsymbol{x}^I$ por $\boldsymbol{x}_r^c$ nessa iteração.

(**V**) Se $f(\boldsymbol{x}^c) = f(\boldsymbol{x}_r^c)$ a solução $\boldsymbol{x}^c$ é ótima para o problema $\mathcal{P}^c$.

(**V**) Se $f(\boldsymbol{x}^I) \leq f(\boldsymbol{x}_r^c)$ então faz sentido podar esse nó.

Questão 5

Sobre o algoritmo *Branch and Bound* para a resolução de problemas de otimização linear inteira mista (**MILP**), explique:

a) Quando que o algoritmo deve fazer o processo de *branching*, isto é, quando ele deve dividir um problema em dois subproblemas?

b) Em quais casos o algoritmo deve realizar o processo de *bounding*, isto é, quando ele deve podar aquele nó e parar de subdividir o problema em problemas menores?

Gabarito:

a) O algoritmo deve fazer o processo de *branching* se o problema relaxado associado àquele nó tiver uma solução melhor que a solução incumbente e que viola alguma restrição de integralidade.

b) O algoritmo deve fazer o processo de *bounding* em 3 casos. Quando o problema relaxado for infactível (*Critério de Infactibilidade*), quando o problema relaxado resultar numa solução inteira (*Critério de Integralidade*) ou quando o problema relaxado resultar em uma solução não melhor que a solução incumbente (*Critério de Poda*).

Questão 6

Observe e analise os problemas abaixo e os classifique entre problema de otimização linear (**LP**), problema de otimização não linear (**NLP**), problema de otimização inteira mista (**MILP**) e problema de otimização não linear inteira mista (**MINLP**).

$$
\begin{aligned}
\min \quad & \sum_{i=1}^{M}\sum_{j=1}^{N} c_{i,j}x_{i,j} \\
\text{s.a:} \quad & \sum_{i=1}^{M} x_{i,j} = 1 \quad j \in \{1,\ldots,N\} \\
& \sum_{j=1}^{N} x_{i,j} \leq 1 \quad i \in \{1,\ldots,M\} \\
& x_{i,j} \in \{0,1\} \quad (i,j) \in \{1,\cdots,M\} \times \{1,\cdots,N\}
\end{aligned}
\tag{A}
$$

$$
\begin{aligned}
\min \quad & \sum_{i=1}^{p}\sum_{j=1}^{q} c_{i,j}x_{i,j} \\
\text{s.a:} \quad & \sum_{j=1}^{q} x_{i,j} = P_i \quad i \in \{1,\ldots,p\} \\
& \sum_{i=1}^{p} x_{i,j} \leq Q_j \quad j \in \{1,\ldots,q\} \\
& x_{i,j} \geq 0 \quad (i,j) \in \{1,\cdots,p\} \times \{1,\cdots,q\}
\end{aligned}
\tag{B}
$$

$$
\begin{aligned}
\min \quad & \sum_{i=1}^{n}\left(y_i - \sum_{j=1}^{p}\beta_j x_{i,j}\right)^2 \\
\text{s.a:} \quad & \beta_j \in \mathbb{R}, \quad \forall j \in \{1,\cdots,p\}
\end{aligned}
\tag{C}
$$

$$\begin{array}{ll} \min & f(\boldsymbol{x}) = \frac{1}{2}\boldsymbol{x}^T Q\boldsymbol{x} - \boldsymbol{b}^T\boldsymbol{x} \\ \text{s.a.} & \boldsymbol{x} \in \mathbb{R}^n. \end{array} \tag{D}$$

$$\begin{array}{ll} \min & -\displaystyle\sum_{i=1}^{n}\sum_{k=1}^{K} y_{i,k} \log\left(\frac{e^{\boldsymbol{w}_k^\top \boldsymbol{x}_i}}{\sum_{j=1}^{K} e^{\boldsymbol{w}_j^\top \boldsymbol{x}_i}}\right) \\ \text{s.a:} & \boldsymbol{w}_k \in \mathbb{R}^p \quad \forall k \in \{1, \cdots, K\} \end{array} \tag{E}$$

$$\begin{array}{lrcrl} \min & x_1^2 & + & x_2^2 & \\ \text{s.a:} & & & x_1 x_2 & \geq 1 \\ & x_1 & , & x_2 & \in \mathbb{R} \end{array} \tag{F}$$

$$\begin{array}{lll} \min & \displaystyle\sum_{i=1}^{n} (c_i y_i + \sqrt{x_i}) & \\ \text{s.a:} & x_i \leq M y_i & \forall i \in \{1, \cdots, n\} \\ & x_i \in \mathbb{R}_+,\ y_i \in \{0,1\} & \forall i \in \{1, \cdots, n\} \end{array} \tag{G}$$

$$\begin{array}{lll} \max & \displaystyle\sum_{j=1}^{n} v_j x_j & \\ \text{s.a:} & \displaystyle\sum_{j=1}^{n} c_j x_j \leq C & \\ & x_j \in \{0,1\}, & \forall j \in \{1, \cdots, n\}. \end{array} \tag{H}$$

Gabarito:

(A) **MILP**

(B) **LP**

(C) **NLP**

(E) **NLP**

(D) **NLP**

(F) **NLP**

(G) **MINLP**

(H) **MILP**

Questão 7

Implemente um algoritmo de *busca tabu* para resolver o problema do Caixeiro Viajante (TSP) em duas instâncias, uma com 20 e outra com 100 cidades. Use instâncias aleatórias geradas com coordenadas euclidianas. A seguir, responda os itens abaixo.

a) Compare a melhor solução encontrada pela busca tabu com a melhor solução encontrada usando um solver exato (ex: `pulp`, `scipy.optimize`, etc.). Use um critério de parada de tempo.

b) Plote a *evolução do custo da solução tabu* ao longo das iterações utilizando a biblioteca `matplotlib`.

Gabarito:
Adapte o problema a partir do notebook disponibilizado na aula 2 de otimização discreta e gere os grafos a partir da função `gera_grafo()` disponbilizada.

Questão 8

Escreva **V** para **Verdadeiro** e **F** para **Falso** para as afirmativas abaixo acerca da busca tabu.

(**F**) A busca tabu só pode ser implementada para problemas binários, pois necessita de uma vizinhança.

(**F**) Uma das desvantagens da busca Tabu é que o algoritmo pode ficar alternando entre dois pontos consecutivamente caso não exista um melhor vizinho.

(**F**) A busca tabu é uma das poucas heurísticas que tem garantia de atingir a otimalidade caso ela itere por pontos o suficiente no espaço de busca.

(**V**) Dada uma solução $\boldsymbol{x}_k$, uma solução vizinha melhor $\boldsymbol{x}_{k+1}^A$ pode ainda assim não ser visitada se ela pertencer à lista tabu T.

(**F**) A busca tabu só se aplica a problemas de alta dimensionalidade, pois quando o problema é pequeno é comum surgirem casos onde toda a solução vizinha é tabu, o que traria problemas para a execução do algoritmo.

Questão 9

Estude o modelo abaixo acerca do problema de *timetabling*.

$$\min \quad \sum_{c\in C}\sum_{t\in T}\sum_{r\in R} p_{c,t}\, x_{c,r,t} \qquad\qquad\qquad\qquad\qquad\qquad \textbf{(1)}$$

$$\text{s.a.:} \quad \sum_{r\in R}\sum_{t\in T} x_{c,r,t} \qquad = 1 \qquad c \in C \qquad\qquad \textbf{(2)}$$

$$\sum_{c\in C} x_{c,r,t} \qquad \leq 1 \qquad r \in R,\ t \in T \qquad\qquad \textbf{(3)}$$

$$\sum_{c\in C} A_{s,c} \sum_{r\in R} x_{c,r,t} \qquad \leq 1 \qquad s \in S,\ t \in T \qquad\qquad \textbf{(4)}$$

$$x_{c,r,t} \in \{0,1\} \qquad\qquad c \in C,\ r \in R,\ t \in T \qquad \textbf{(5)}$$

C : conjunto de cursos (*Courses*),

R : conjunto de salas (*Rooms*),

T : conjunto de horários (*Times*),

S : conjunto de alunos (*Students*),

$p_{c,t}$: penalidade de alocar o curso $c \in C$ no horário $t \in T$,

$$A_{s,c} : \begin{cases} 1, & \text{se o aluno } s \in S \text{ está matriculado no curso } c \in C, \\ 0, & \text{caso contrário,} \end{cases}$$

$$x_{c,r,t} : \begin{cases} 1, & \text{se o curso } c \in C \text{ é alocado na sala } r \in R \text{ no horário } t \in T, \\ 0, & \text{caso contrário.} \end{cases}$$

Após analisar as variáveis e o modelo escrito responda o que se pede.

a) Analisando a função objetivo **(1)** e as variáveis relacionadas, qual o objetivo desse problema?

b) O que a restrição **(2)** significa? O que significaria violar essa restrição?

c) O que a restrição **(3)** significa? O que significaria violar essa restrição?

d) O que a restrição **(4)** significa? O que significaria violar essa restrição?

e) O modelo anterior permite um aluno estar matriculado em vários cursos? Esse aluno pode estar matriculado em 2 cursos que acontecem ao mesmo tempo?

f) É possível haver alunos que não estão matriculados em nenhum curso? Se quisermos proibir isso, ou seja, forçar com que cada aluno esteja matriculado em ao menos um curso, como podemos adaptar a modelagem?

Gabarito:

a) O objetivo do problema é minimizar a penalidade total associada à alocação dos cursos nos horários respectivos.

b) A restrição **(2)** garante que cada curso c seja atribuído a exatamente uma sala r e um único período t. Violar essa restrição permitiria um curso acontecer em múltiplas salas ou múltiplos períodos.

c) A restrição **(3)** garante que no máximo um curso ocorre numa sala r num determinado período t. Violar essa restrição permitiria uma sala r ter dois cursos sendo lecionados simultaneamente.

d) A restrição **(4)** garante que nenhum aluno está matriculado em cursos que ocorrem simultaneamente. Violar a restrição significa que um aluno poderia se matricular em dois cursos que ocorrem simultaneamente.

e) Sim, o aluno pode estar matriculado em vários cursos, desde que eles ocorram em períodos diferentes. O aluno não pode estar matriculado em dois cursos que ocorrem simultaneamente pela restrição **(4)**.

f) É possível que um aluno não esteja matriculado em nenhum curso por conta da desigualdade ≤ 1 na restrição **(4)**.

Se $A_{s,c} = 0$ para todo $(s, c) \in S \times C$, por exemplo, essa desigualdade continua satisfeita. É possível evitar isso adicionando a restrição

$$\sum_{c \in C} A_{s,c} \geq 1, \quad s \in S$$

ao modelo.

Questão 10

Das situações abaixo, apenas uma **não** pode ser modelada pelo modelo k-means apresentado. Identifique qual é essa situação e explique o porquê.

a) Identificar perfis de investimento a partir da renda mensal e do saldo médio de clientes de um banco.

b) Segmentar regiões de cor em uma imagem digital com base nos valores RGB dos pixels.

c) Classificar mensagens eletrônicas como indesejadas ou não indesejadas a partir de rótulos já existentes.

d) Organizar estações meteorológicas em grupos segundo as medições de temperatura e umidade registradas.

e) Mapear zonas de maior tráfego de dados analisando as coordenadas (latitude/longitude) dos sensores IoT espalhados pela cidade.

Gabarito:

O k-means é um método de *clustering* **não-supervisionado** que agrupa pontos de dados com base em distâncias em $\mathbb{R}^d$, sem utilizar rótulos pré-definidos. A situação (C) exige classificação **supervisionada** por meio do uso de rótulos "spam"/"não spam"para treinar o modelo, o que foge ao escopo do k-means.